

西安交通大学

硕士学位论文

基于信号多视角融合与域迁移的三维点云重建方法研究

学位申请人：张沐薪

指导教师：王鸽 副教授

类别（领域）：工程硕士（计算机技术）

2025 年 04 月

Research on 3D Point Cloud Reconstruction Method Based on Multi-View Signal Fusion and Domain Transfer

A thesis submitted to
Xi'an Jiaotong University
in partial fulfillment of the requirements
for the degree of
Master of Engineering

By
Muxin Zhang
Supervisor: Associate Prof. Ge Wang
Master of Engineering (Computer Technology)
April 2025

摘要

三维重建技术历经数十年发展已取得显著突破，并在工业检测、自动驾驶、文化遗产保护等领域广泛应用，为目标识别、场景理解等下游任务提供高精度空间信息支持。然而，传统的基于图像的三维重建方法在一些特定场景下仍存在局限性，例如物流分拣和安检领域，目标物体常被包裹覆盖，且环境光照条件受限或存在视觉遮挡，导致基于图像的方法失效。现有基于射频信号的三维重建方法多依赖复杂射频系统，硬件成本高昂，同时，其中基于深度学习的方法往往存在依赖大量真实标注数据以及迁移成本高等问题。因此，开发一种兼具低成本与穿透能力的三维重建方法具有重要研究意义。本文针对上述问题，展开了如下两个方面的研究：

首先，针对现有基于图像的三维重建方法在视觉遮挡场景下失效的问题，本文提出了一种基于信号多视角逆投影融合的三维点云重建方法。该方法仅利用低成本的单发单收商用超宽带雷达构建虚拟天线阵列对物体进行信号采集，并通过背景反射消减以及有效距离箱定位获取到去噪后的有效目标信号；针对雷达数据多样性不足的问题，设计了虚拟天线偏移和相位旋转数据增强方法；之后通过三维重建神经网络模型从雷达信号中提取物体三维结构信息并生成多视角深度图，并通过深度图逆投影和点云融合生成重建点云。在自建数据集上的实验表明，本方法重建点云的倒角距离（Chamfer Distance, CD）误差为 5.326cm，2cm/4cm 阈值下的 F1 分数分别为 62.17% 与 76.34%；在物体完全遮挡场景中，重建点云 CD 误差相比于非遮挡场景仅上升 0.977 cm，验证了本方法在遮挡场景的鲁棒性。

其次，针对基于深度学习的三维重建方法依赖大量真实标注数据，迁移成本高等问题，本文提出了一种基于信号域迁移的三维点云重建方法。本文通过对物体反射信号进行详细建模设计并实现了雷达信号仿真算法，同时设计了信号域适应神经网络模块，用于减少信号在仿真域和真实域上的分布差异，并最终构建了一个大规模仿真信号数据集；之后使用迁移学习的方法，首先将三维重建网络模型在仿真信号数据集上做预训练，随后迁移到真实信号数据集上微调，以提升模型的数据效率、训练速度和性能表现。在基于信号域迁移的三维点云重建方法下，重建点云的 CD 误差为 4.868cm，相比于从头训练的方法 CD 误差下降了 0.458cm，获得了更高的点云重建精度；当仅保留真实信号数据集中 5% 的训练数据对三维重建网络模型进行微调，重建点云的 CD 误差为 5.175cm，相比于全量训练数据微调时的重建点云 CD 误差仅上升 0.307cm，大幅提升了网络模型的数据效率；同时，三维重建网络模型在真实信号数据集上的训练周期由 50 个 epoch 缩短为仅 8 个 epoch，大大降低了训练成本。

关 键 词： 脉冲超宽带雷达；无线感知；三维重建；迁移学习；

论文类型： 应用研究

ABSTRACT

3D reconstruction technology has made significant breakthroughs over decades of development and has been widely applied in fields such as industrial inspection, autonomous driving, and cultural heritage preservation, providing high-precision spatial information support for downstream tasks like object recognition and scene understanding. However, traditional image-based 3D reconstruction methods still have limitations in certain specific scenarios, such as logistics sorting and security inspection, where target objects are often covered by packaging materials, and environmental lighting conditions are restricted or visual occlusion exists, causing image-based methods to fail. Existing radio frequency (RF) signal-based 3D reconstruction methods mostly rely on complex RF systems with high hardware costs. Additionally, deep learning-based approaches often suffer from issues such as dependency on large amounts of labeled real-world data and high migration costs. Therefore, developing a 3D reconstruction method that combines low cost with penetration capability holds significant research value. This thesis addresses the above challenges through the following two research directions:

First, to address the failure of existing image-based 3D reconstruction methods in visually occluded scenarios, this thesis proposes a 3D point cloud reconstruction method based on multi-view inverse projection fusion of signals. The method utilizes only a low-cost single-input single-output commercial ultra-wideband radar to construct a virtual antenna array for signal acquisition of objects. Background reflection cancellation and effective range bin localization are applied to obtain denoised target signals. To address the issue of insufficient diversity in radar data, a data augmentation method involving virtual antenna offset and phase rotation is designed. Subsequently, a 3D reconstruction neural network model extracts 3D structural information from radar signals to generate multi-view depth maps, which are then fused through depth map back-projection and point cloud integration to generate reconstructed point clouds. Experiments on a self-built dataset demonstrate that the Chamfer Distance (CD) error of the reconstructed point cloud is 5.326 cm, with F1 scores of 62.17% and 76.34% at 2 cm/4 cm thresholds, respectively. In fully occluded scenarios, the CD error of the reconstructed point cloud increases by only 0.977 cm compared to non-occluded scenarios, validating the robustness of this method in occluded environments.

Second, to address the reliance of deep learning-based 3D reconstruction methods on large amounts of labeled real-world data and high migration costs, this thesis proposes a 3D point cloud reconstruction method based on signal domain adaptation. Detailed modeling of object reflection signals is conducted to design and implement a radar signal simulation algorithm. A signal domain adaptation neural network module is also designed to reduce the distribution dis-

crepancy between simulated and real domains, ultimately constructing a large-scale simulated signal dataset. Transfer learning is then applied: the 3D reconstruction network model is pre-trained on the simulated signal dataset and fine-tuned on the real signal dataset to improve data efficiency, training speed, and performance. Under the proposed signal domain adaptation-based 3D point cloud reconstruction method, the CD error of the reconstructed point cloud is 4.868 cm, representing a reduction of 0.458 cm compared to training from scratch, achieving higher point cloud reconstruction accuracy. When only 5% of the training data from the real signal dataset is retained for fine-tuning the 3D reconstruction network, the CD error of the reconstructed point cloud is 5.175 cm, increasing by only 0.307 cm compared to full-data fine-tuning, demonstrating the network's higher data efficiency. Furthermore, the number of training epochs required for the 3D reconstruction network on the real signal dataset is reduced from 50 to just 8, significantly lowering training costs.

KEY WORDS: IR-UWB Radar; Wireless Sensing; 3D Reconstruction; Transfer Learning

TYPE OF THESIS: Application Research

目 录

摘 要.....	I
ABSTRACT.....	III
1 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 基于传统算法的三维重建.....	2
1.2.2 基于深度学习的三维重建.....	4
1.3 主要研究内容.....	6
1.4 论文组织结构.....	7
2 相关理论与技术.....	8
2.1 脉冲超宽带雷达感知技术.....	8
2.1.1 脉冲超宽带雷达感知原理.....	8
2.1.2 脉冲超宽带雷达数据结构.....	10
2.2 迁移学习.....	11
2.3 本章小结.....	13
3 基于信号多视角逆投影融合的三维点云重建方法.....	14
3.1 引言.....	14
3.2 超宽带雷达信号采集与处理.....	14
3.2.1 超宽带虚拟天线阵列构建.....	14
3.2.2 背景反射消减.....	16
3.2.3 有效距离箱定位.....	17
3.3 雷达信号数据增强.....	19
3.3.1 虚拟天线偏移数据增强.....	20
3.3.2 相位旋转数据增强.....	21
3.3.3 数据增强算法.....	24
3.4 三维重建神经网络模型.....	25
3.4.1 复数信号编码器模块.....	26
3.4.2 解码器模块.....	27
3.4.3 损失函数.....	29
3.5 多视角深度图逆投影及点云融合.....	30
3.6 实验及结果分析.....	32
3.6.1 实验场景布置.....	32
3.6.2 数据集采集.....	32

3.6.3 评估指标.....	33
3.6.4 实验设置.....	34
3.6.5 实验效果及评估.....	35
3.7 本章小结	39
4 基于信号域迁移的三维点云重建方法.....	41
4.1 引言	41
4.2 基于信号建模的雷达信号仿真	41
4.2.1 三维物体反射信号物理建模.....	42
4.2.2 物体三维网格细分及遮挡面去除.....	45
4.2.3 雷达信号仿真算法.....	48
4.3 信号域适应网络模块	50
4.3.1 神经网络模型.....	50
4.3.2 损失函数设计.....	53
4.4 仿真信号域迁移	53
4.4.1 仿真信号数据集.....	53
4.4.2 基于迁移学习的两阶段训练.....	55
4.5 实验及结果分析	56
4.5.1 域适应实验评估.....	56
4.5.2 域迁移实验评估.....	58
4.6 本章小结	62
5 结论与展望.....	63
5.1 结论	63
5.2 展望	63
参考文献.....	65
声明	

CONTENTS

ABSTRACT (Chinese)	I
ABSTRACT (English)	III
1 Introductions	1
1.1 Research Background and Significance	1
1.2 Research Status at Home and Abroad	2
1.2.1 3D Reconstruction Based on Traditional Algorithms	2
1.2.2 3D Reconstruction Based on Deep Learning	4
1.3 Research Content of Thesis	6
1.4 Thesis Organization Structure	7
2 Related Theory and Technology	8
2.1 Impulse Radio Ultra-Wideband (IR-UWB) Radar Sensing Technology	8
2.1.1 Impulse Radio Ultra-Wideband (IR-UWB) Radar Sensing Theory	8
2.1.2 Impulse Radio Ultra-Wideband (IR-UWB) Radar Data Structure	10
2.2 Transfer Learning	11
2.3 Summary	13
3 3D Point Cloud Reconstruction Method Based on Multi-View Signal Back-Projection Fusion	14
3.1 Introduction	14
3.2 Ultra-Wideband Radar Signal Acquisition and Processing	14
3.2.1 Construction of Ultra-Wideband Virtual Antenna Arrays	14
3.2.2 Background Reflection Reduction	16
3.2.3 Useful Range Bin Localization	17
3.3 Radar Signal Data Augmentation	19
3.3.1 Virtual Antenna Shift Data Augmentation	20
3.3.2 Phase Rotation Data Augmentation	21
3.3.3 Data Augmentation Algorithm	24
3.4 3D Reconstruction Neural Network Model	25
3.4.1 Complex Signal Encoder Module	26
3.4.2 Decoder Module	27
3.4.3 Loss Function	29
3.5 Multi-View Depth Map Back-Projection and Point Cloud Fusion	30
3.6 Experiment and Result Analysis	32
3.6.1 Experimental Environment Setup	32

3.6.2 Dataset Collection	32
3.6.3 Metric.....	33
3.6.4 Experiment Setup	34
3.6.5 Experimental Results and Evaluation	35
3.7 Summary	39
4 3D Point Cloud Reconstruction Method Based on Signal Domain Transfer.....	41
4.1 Introduction	41
4.2 Radar Signal Simulation Based on Signal Modeling	41
4.2.1 Physics-Based Modeling of 3D Object Reflection Signals	42
4.2.2 3D Mesh Subdivision of Objects and Occluded Surface Removal	45
4.2.3 Radar Signal Simulation Algorithm	48
4.3 Signal Domain Adaptation Network Module.....	50
4.3.1 Neural Network Model.....	50
4.3.2 Loss Function Design	53
4.4 Simulated Signal Domain Transfer	53
4.4.1 Simulated Signal Dataset	53
4.4.2 Two-stage Training based on Transfer Learning	55
4.5 Experiments and Results Analysis	56
4.5.1 Domain Adaptation Experimental Evaluation	56
4.5.2 Experimental Evaluation of Domain Transfer	58
4.6 Summary	62
5 Conclusion and Suggestions	63
5.1 Conclusion	63
5.2 Suggestions	63
References	65
Declarations	

1 绪论

1.1 研究背景及意义

三维重建技术在过去几十年的发展中取得了显著的技术突破，并在工业制造^[1-3]、文化遗产保护^[4-6]、自动驾驶^[7-9]等多个领域实现了广泛应用。其核心优势在于能够通过多视角几何分析、特征匹配与深度学习等技术，从二维图像或传感器数据中高效构建出物体或场景的三维几何模型，从而为后续的分析、模拟与决策提供高精度的空间信息支持。例如，在工业检测中，基于结构光或 ToF（Time of Flight）相机的三维重建技术能够实现对复杂工件的高精度形貌测量；在自动驾驶领域，激光雷达（LiDAR）与视觉 SLAM（Simultaneous Localization and Mapping）的结合则为环境感知与路径规划提供了实时的三维场景理解能力。这些技术的成功应用不仅推动了相关行业的自动化进程，也验证了三维重建在解决空间认知问题中的核心价值。然而，尽管现有方法在开放、可见度良好的场景中表现优异，其技术局限性在特定复杂场景下仍日益凸显，尤其在物流分拣与安检领域，传统方法面临关键挑战。

在物流分拣场景中，三维重建技术的性能瓶颈主要源于两个方面：其一，待分拣的物体常被多层包装材料（如纸箱、塑料膜）覆盖，导致基于视觉的三维重建方法（如 RGB-D 相机、立体视觉系统）因表面纹理缺失或反射干扰而无法有效获取目标物体的真实几何信息；其二，基于图像的三维重建方法仅关注物体表面，针对物体的内部结构无法进行有效的重建，并且基于图像的方法在计算成本上也有着较大的开销。类似的问题在安检领域同样突出：危险品或违禁品可能被故意包裹在行李或货物中，传统的 X 射线成像虽能穿透包装，但其二维投影图像缺乏三维空间信息，难以精准识别物体的三维姿态与内部结构，且对操作人员的经验依赖性较高。因此，现有基于图像的三维重建方法在这些场景中已无法满足实际需求。

为应对上述挑战，研究者开始探索具有穿透能力的三维重建技术。其中，基于射线的三维重建方法因能够穿透非金属材料而受到关注。例如，通过分析电磁波反射信号的时延与相位差，可构建物体的三维轮廓，甚至识别内部结构。然而，这类技术的商业化应用仍面临显著障碍：首先，高精度射频系统需要复杂的硬件配置（如大型多入多出天线阵列），导致设备成本高昂，难以在物流仓储或安检等对成本敏感的场景中普及；其次，射频信号的分辨率与成像速度通常受限于电磁波波长，难以在保证穿透能力的同时实现高精度三维建模。因此，尽管射频技术在原理上具备穿透优势，但其工程化应用仍需突破成本与性能的双重瓶颈。

为了解决上述问题，本文提出了一种基于信号多视角融合与域迁移的三维点云重建方法。该方法仅使用一个低成本的商用单发单收脉冲超宽带雷达实现了对物体的三维点云重建；本文首先利用了物流和安检场景下目标物体相对于雷达的相对运动，为

超宽带雷达构建出虚拟天线阵列，进一步提升雷达的感知能力；之后使用三维重建神经网络模型从雷达信号中提取物体三维结构特征，生成物体多视角下的深度图，并最终通过深度图逆投影和点云融合技术得到了最终的重建点云。同时，基于深度学习的三维重建方法存在着依赖大量真实标注数据、迁移成本高等缺点，本文通过信号域迁移的方法来解决上述问题，本文首先通过信号仿真和信号域适应神经网络模块构建出规模巨大的仿真信号数据集，之后将三维重建神经网络模型在仿真信号和真实信号之间进行域迁移，大幅提升了三维重建神经网络模型在真实信号数据集上的数据效率和训练速度，并在一定程度上提升了模型的性能表现。该方法实现了低成本、具有穿透能力、迁移成本低的三维点云重建，是对现有三维重建方法的一个重要补充，具有一定的研究意义。

1.2 国内外研究现状

高效、鲁棒的三维重建方法对于下游的任务起着至关重要的作用，学术界和工业界也从未停止过对三维重建方法的创新和优化，近几十年间，研究人员已经提出了许多成熟的三维重建方法，这些方法在大部分应用场景也都取得了非常良好的表现，但针对某些特殊场景，现有的三维重建方法仍然存在着一些不足之处。现有的三维重建方法大致可以分为两大类，即基于传统算法的三维重建和基于深度学习的三维重建，下面就这两类方法对已有的工作进行介绍。

1.2.1 基于传统算法的三维重建

1) 基于 RGB 图像的传统三维重建

使用二维图像来重建出物体或场景的三维结构长久以来一直作为计算机视觉领域的一个重要课题。基于 RGB 图像的传统三维重建方法大致可以分为两类，即稀疏点云重建和稠密点云重建。

稀疏点云重建使用的方法被称为运动恢复结构 (Structure from motion, SFM)，首先输入一个场景或物体的多视角图像，检测其中每个图像中的特征点并进行跨图像匹配，然后运用 SFM 重构算法，恢复出相机的参数和相对位置以及场景或物体的稀疏点云。Lowe 等^[10]提出了著名的尺度不变特征变换算法 (Scale Invariant Feature Transform, SIFT)，该算法用于寻找图像中局部特征点，并为特征点生成对应的描述符，用于特征点匹配，该算法具有尺度、旋转及亮度不变性等特征，但也存在着计算量大等缺点。Bay 等^[11]提出了一种计算速度更快的特征点检测和描述算法，加速稳健特征算法 (Speeded Up Robust Features, SURF)，该算法同样具有旋转不变性、尺度不变性、鲁棒性好等特征。Rublee 等提出了运算速度更快的特征点检测和描述算法 ORB (Oriented FAST and Rotated BRIEF)^[12]，该算法是分别对 FAST (Features from Accelerated Segment Test)^[13]特征检测算法和 BRIEF (Binary Robust Independent Elementary Features)^[14]特征描述算法进行了优化并将两者结合起来，该算法要比 SIFT 快两个数量级，然而该算法并不具备尺度不变性特征。SFM 重构的思想是利用多张图像计算出相机的位置信息以及运动轨

迹,从而在空间坐标系下生成稀疏三维点云。传统的 SFM 重构方法分为增量式^[15]和全局式^[16],增量式 SFM 重构是指先使用两张图像计算相机位姿并重建部分场景,之后不断添加新的图像调整相机位姿并重建场景;全局式 SFM 重构是指将所有图像添加到场景中,并计算相机位姿并重建场景。2017 年, Cui 等^[17]将两者进行了结合,提出了混合式 SFM。

由于 SFM 是用特征匹配得到的关键点来进行点云重建的,因此得到的是稀疏点云,一般需要进一步完善,即稠密点云重建,使用的方法被称为多视角立体视觉 (Multi-View Stereo, MVS)。MVS 的主要任务是通过最佳搜索的方法,对不同图像上的点进行像素级别的匹配,构建场景的稠密点云。MVS 中的关键步骤是深度图的计算,针对深度图计算,研究人员提出了大量的算法。Gallup 等^[18]将 Plane-Sweeping 算法用于计算深度图,主要思想是将深度范围分为一个个平面,如果空间中一点在物体表面,那么所有能看到该点的相机应该都看到同一个颜色。Bleyer 等^[19]将 PatchMatch 算法应用于深度图计算, PatchMatch 算法通过随机初始化,之后通过迭代地传播和优化像素块之间的匹配关系,生成高质量的深度图。

上述方法在常规场景下的稀疏点云重建和稠密点云重建上取得了非常好的效果,然而这些方法非常依赖于相机的内外参数的高质量标定并且大多计算复杂度较高,同时,由于 RGB 图像的固有缺陷,在光照条件不足以及存在遮挡的情况下性能严重受限。

2) 基于其他传感器的传统三维重建

由于基于 RGB 图像的方法仍然存在着一些缺陷,例如重建效果受光照条件和环境可见度影响非常大,计算复杂度高等。因此,也有许多基于其他传感器的三维重建方法被提出,这些传感器大多是主动式传感器,例如激光雷达, TOF 相机,毫米波雷达等。

激光雷达 (LiDAR) 通过激光束的扫描,可以很方便地得到周围环境的深度信息,因此常被用来进行三维点云重建。Schwalbe 等^[20]使用激光雷达去获取点云数据,之后对点云数据进行分段投影,完成了建筑物的三维模型重建。Weiss 等^[21]使用激光雷达提取了前方车辆的轮廓信息并对目标车辆进行了三维重建,并最终实现了目标车辆检测。文献[22]使用车载激光雷达实现了建筑物点云立面几何三维重建。

TOF (Time of flight) 技术是通过发射端不断向物体发射脉冲光,计算发射和接受的时间差获取物体深度信息,从而进行三维重建。因此目前已经有许多消费级的 TOF 相机,例如微软的 Kinect v2,这些产品被广泛应用于物体和环境建模,如文献[23]。

毫米波雷达 (Millimeter-Wave Radar) 是指发射的射频信号波长在毫米级别的雷达,具有较高的距离分辨率和较强的穿透能力。文献[24]设计了一个使用毫米波雷达进行三维点云生成的系统 Millipoint。Yanik 等^[25]使用毫米波雷达构建了多输入多输出 (Multiple-Input Multiple-Output, MIMO)-合成孔径雷达 (Synthetic Aperture Radar, SAR) 系统,通过将毫米波雷达固定在两轴导轨上沿两个轴进行运动来扩大雷达孔径,实现了对物体的三维成像,但该系统进行一次二维扫描耗时较长,并且需要配备专业的运动导轨,成本较高。

上述传感器中，由于激光雷达和 TOF 相机发射的电磁波仍然在近红外波段附近，因此虽然对于雨雾，浮尘等有着不错的穿透性，但是当物体被一些轻薄遮挡物遮挡时，基于这类传感器的三维重建方法将不再适用。毫米波雷达相较于前两者，使用的电磁波拥有着更大的波长，因此对于一些轻薄的遮挡物例如纸盒、塑料包装等是有较好的穿透性，在物体被遮挡的场景下的三维重建效果会更好一些，但同时距离分辨率不如前两者，因此重建的精度也并不理想，同时商用的毫米波雷达大多数集成了多个发射天线和接收天线，成本较高。

1.2.2 基于深度学习的三维重建

随着近年来深度学习的迅猛发展，三维重建领域的研究人员逐渐将兴趣从传统方法转向基于深度学习的方法，传统三维重建方法依赖于手工设计的特征提取算法，而基于深度学习的方法通过神经网络强大的特征提取和表征能力，能够自动从大量数据中学习到三维表征，实现三维结构的重建。

1) 基于 RGB 图像的深度学习三维重建

由于手工设计的特征提取算法很难从单张图像中提取出物体的深度信息，因此传统方法很难实现基于单张图像的三维重建，然而深度学习能够从大量数据中学习到低级纹理特征以及高级语义特征，使得基于单张图像的三维重建成为了可能。PointOutNet^[26]被提出用于从单个图像中重建物体点云。该网络模型结构非常简单，由一个卷积编码器和两个并行预测分支组成，两个预测分支分别为全连接分支和反卷积分支，两个分支的输出合并在一起形成点云。该工作的一大贡献是引入了倒角距离（Chamfer Distance）损失函数，该损失函数可以很好地对模型最终输出的点云进行约束，同时该损失函数对点云中点的不同排列具有不变性，许多其它工作也使用了该损失函数^[27-28]。RealPoint3D^[29]提出了一种端到端的从单张图像到三维点云的高效生成网络模型，该模型由编码器、二维三维融合模块和解码器组成。该工作通过将 ShapeNet 数据集^[30]中最接近的形状作为网络的辅助输入去进行有效指导，实验表明该方法在处于复杂背景的单张图像上仍表现良好。相较于三维点云的重建，三维网格的重建更具挑战性。Residual MeshNet^[31]是一个从单张图像重建三维网格的网络模型，该网络使用 ResNet^[32]作为初始的图像特征提取器，之后将图像特征和初始网格输入到由多层感知机（Multi-Layer Perceptron, MLP）组成的堆叠块，这样的堆叠块有多个，每个对应一个处理阶段，每个阶段输出网格的变形版本，相邻的堆叠块之间存在残差连接。这项工作是较早开始探究从单张图像去重建三维网格的工作，然而它在如何重建出较平滑的三维网格上存在着挑战。Pixel2Mesh^[28]是另一个实现从单张图像重建三维网格的工作，该网络模型使用了图卷积神经网络（Graph Convolutional Network, GCN）分三阶段将初始的椭圆体网格逐步变形成目标三维网格，变形过程中逐步增强网格分辨率并修正顶点坐标位置。该工作设计了多种网格相关的损失函数，使得重建出的三维网格在视觉上更平滑逼真。

也有大量工作使用深度学习的方法从多张图像去进行三维重建。Pixel2Mesh++^[33]是 Pixel2Mesh 的改进工作，该工作使用少量的不同视角图像去对物体进行三维网格重建。

作者将 Pixel2Mesh 中使用的 GCN 换成了一种新提出的网络结构, 被称为多视图变形网络 (Multi-View Deformation Network, MDN), MDN 并不是像 GCN 一样去学习物体的形状先验, 而是通过一种物理驱动的体系结构根据多视图之间的相关性对形状进行推理, 确保了最终输出的三维网格在各个视角上都有良好精度。3D4D^[34]实现了从多视角图像去重建物体三维点云, 该工作强调了网络模型的泛化性, 即对于训练过程中未见过的物体类别的重建效果^[35], 实验表明对于人工合成物体的渲染图像, 该工作具有良好的泛化性, 但对于实际中的新类别物体或更复杂的集合形状上效果不佳^[36]。受到传统多视角立体视觉 (Multi-View Stereo, MVS) 方法的启发, Yao 等^[37]提出了一个端到端的 MVS 网络模型 MVSNet, 该网络模型使用二维卷积神经网络从输入的多视角图像中提取深度特征, 之后基于相机参数, 将源图像特征投影到参考图像视角的不同深度平面上, 构建代价体 (Cost Volume), 之后使用三维卷积神经网络去对初始深度图进行正则化和回归, 最后使用参考图像进行完善生成最终深度图。实验表明该方法相比于传统 MVS 方法在准确性和完整性上显著提升, 该工作也引出了后续的一系列工作^[38-42], 这些工作在 MVSNet 运算时间长、消耗内存大等缺陷上做了改进, 并在准确性和完整性上做了进一步优化。MVSNet 系列工作之后的又一热门为 NeRF 系列。Mildenhall 等^[43]首先提出了名为 NeRF 的方法, 它利用神经辐射场来表示连续场景中复杂的集合形状和材料, 通过 MLP 去从已有视角图像中隐式地学习辐射场中每个点的颜色和密度, 之后通过体积渲染可以生成任意视角的图像, 该方法生成的新视角图像质量高, 细节逼真, 但也存在一些局限, 例如针对每个单独场景都需要进行单独的训练, 并且训练速度慢 (数小时甚至数天), 依赖大量的输入视图等。后续有不少工作对 NeRF 做了改进, 例如文献[44-46]实现了对 NeRF 的训练和渲染进行加速, 文献[47-48]则尝试减少 NeRF 对密集视角输入的依赖。三维高斯溅射 (3D Gaussian Splatting, 3DGS)^[49]是 NeRF 之后的又一开创性工作, 3DGS 和 NeRF 的优化方式是一致的, 即通过将渲染出来的图像和真实图像计算损失函数, 通过梯度下降去进行优化, 3DGS 不同于 NeRF 对场景进行隐式表示, 而是使用三维高斯分布直接去建模场景和外观, 相比于 NeRF, 3DGS 在训练和渲染速度上取得了非常大的进步, 对于单一场景的训练仅需几分钟。

上述基于 RGB 图像的深度学习三维重建方法, 在一定程度上减少了对于相机内外参精确标定的依赖, 并且凭借现代硬件加速技术 (如 GPU) 大大提升了重建速度, 但仍未解决基于 RGB 图像的方法在可见性较差以及遮挡场景下的性能问题。

2) 基于射频信号深度学习三维重建

为了克服使用图像的三维重建方法在可见性差以及物体被遮挡情况下的性能缺陷, 也有一些研究人员尝试了使用无线射频信号的基于深度学习的三维重建。

Zhao 等^[50]使用 wifi 信号在有遮挡物、身着宽松衣服、光照条件不好的场景下对人体进行了三维网格重建, 该工作提出了一种名为 RF-Avatar 的神经网络模型, 使用强监督弱监督相结合、多头自注意力机制等技术解决了从 wifi 信号推断人体三维网格这一高度受限的问题, 但该工作使用的射频设备较为复杂, 并且设计的网络模型无法实现

实时的推理。Xue 等^[51]使用商用毫米波雷达实现了一个实时的人体三维网格估计系统，该工作首先从毫米波雷达信号生成人体的稀疏点云，之后使用神经网络从稀疏点云中估算出复杂且逼真的人体三维网格，最终产生的三维网格具有出色的精度。该工作的局限是，网络模型的性能很大程度依赖于训练集中包含的数据模式的完整性和代表性，这也是基于深度学习的方法的普遍问题，于是作者之后又提出了 mmGPE^[52]，在该工作里，作者提出了一个新型的射频信号数据增强框架，该框架使用物理模拟结合深度学习的方法来为实际采集信号过程中并未见过的人体动作生成对应的毫米波信号，通过这种数据增强方法，使得网络模型对于从未见过的人体动作，仍然能生成精度较高的对应人体三维网格。上述工作在一定程度上实现了利用射频信号进行人体的三维网格重建，但人体三维网格的基本结构较为固定，由头部、躯干、四肢等部分组成，模型比较容易得到较多的先验知识，因此重建难度较低，对于普适的物体三维重建，上述方法并不适用。文献[53] 使用三发四收的商用毫米波雷达搭配在水平和垂直两个方向运动的滑轨对物体进行扫描并进行雷达信号采集，之后通过基于深度学习的两阶段生成对抗网络从原始毫米波雷达数据实现了物体的三维点云重建，文献[54-55] 在文献[53] 的基础上对第二阶段的生成对抗网络进行进一步优化，提升了原有方法的重建精度，但这些方法缺乏在大规模真实数据集上的评估。

综上所述，现有的基于射频信号的深度学习三维重建方法一定程度上解决了基于图像的三维重建方法的固有缺陷，但在重建精度以及适用场景上仍存在较大不足，同时，上述几个工作所使用的无线射频设备都是集成多根发射天线和接收天线的复杂射频设备，成本较高。

1.3 主要研究内容

本文提出了一种基于信号多视角融合与域迁移的三维点云重建方法，该方法使用低成本的商用单发单收脉冲超宽带雷达实现了对物体的三维点云重建，该方法不受环境可见性影响，即使在物体被遮挡的情况下依然适用，同时一定程度上克服了基于深度学习的三维重建方法存在的依赖大量真实标注数据、迁移成本高等缺点，是对现有的三维重建方法的一个重要补充。具体来说，本文的主要工作由两部分构成：

1) 本文提出了一种基于信号多视角逆投影融合的三维点云重建方法，该方法利用物体相对超宽带雷达的运动构建出超宽带虚拟阵列，提升了雷达的感知能力，之后对雷达信号进行背景反射消减和有效信号定位，得到去噪后的有效信号；随后针对雷达信号数据集样本单一的问题，本文设计了雷达信号数据增强算法，对雷达数据进行扩充；接着设计了一个从多视角雷达信号到物体多视角深度图的三维重建神经网络模型，并最终通过深度图逆投影和点云融合得到了物体重建三维点云。

2) 本文提出了一种基于信号域迁移的三维点云重建方法。针对基于深度学习的三维重建方法存在着的真实雷达信号数据采集耗时、标注费时以及网络模型迁移时训练成本高等问题，本文使用信号域迁移的方法来解决上述问题。本文首先设计并实现

了基于信号建模的雷达信号仿真算法，随后设计了信号域适应网络模块，通过这两个步骤可以合成出一个数据量庞大的仿真信号数据集；随后使用“预训练-微调”的两阶段训练范式将三维重建神经网络模型在仿真信号和真实信号之间进行域迁移，以此提升网络模型在真实信号数据集上的数据效率、训练速度以及性能表现。

1.4 论文组织结构

本文总共分为五个章节，各章节具体内容如下：

第一章为绪论部分。首先介绍了本文的研究背景和相关研究的应用价值，接着分析了国内外研究物体三维重建方法的现状，总结了现有方法的不足，并给出了本文的主要贡献和创新点。

第二章为相关理论与技术部分。在第一小节中介绍了脉冲超宽带雷达感知技术，包括脉冲超宽带雷达感知原理以及对应的雷达数据结构；在第二小节中介绍了迁移学习的定义以及应用。

第三章为基于信号多视角逆投影融合的三维点云重建方法。首先介绍了超宽带虚拟阵列信号采集与处理流程，随后介绍了雷达信号数据增强算法，接着介绍了三维重建神经网络模型及各模块的设计，之后介绍了深度图逆投影和点云融合流程，最后通过实验评估了本文的三维点云重建方法的性能表现，并且验证了本文方法在物体被遮挡情况下的鲁棒性，同时使用消融实验验证了本文提出的数据增强方法的有效性。

第四章为基于信号域迁移的三维点云重建方法。首先介绍了本文提出的基于信号建模的雷达信号仿真算法，接着介绍了本文设计的信号域适应网络模块；随后详细介绍了三维重建神经网络模型从仿真信号数据集到真实信号数据集的迁移学习步骤，其中还包括了仿真信号数据集的生成方法；最后通过实验评估验证了本文的信号仿真算法和信号域适应网络模块的有效性，以及验证了本文的从仿真域到真实域的迁移学习方法对三维重建神经网络模型的数据效率、训练速度和整体性能的提升。

第五章为结论与展望，主要对本文所做工作做了大致总结，指出主要贡献和创新点；之后对目前工作的不足之处进行分析，对未来工作进行了展望。

2 相关理论与技术

2.1 脉冲超宽带雷达感知技术

超宽带 (Ultra-Wideband, UWB) 射频是指工作频率带宽超过 500MHz 的射频信号, 由于超宽带射频大多是通过发射极短的无线电脉冲来实现如此高的工作频率带宽, 因此也被称为脉冲超宽带 (Impulse Radio Ultra-Wideband, IR-UWB)。该射频信号的核心特点在于极宽的频谱带宽和极低的功率谱密度, 得益于这两点, 超宽带信号可以在短时间内传输大量信息, 而不会干扰同一频段的传统窄带和载波传输, 因此, 超宽带射频已经被广泛地应用于无线通信领域。超宽带射频能够穿透障碍物并且捕获到环境中细微的变化, 同时具有极高的时间分辨率, 能够实现对目标物体的精确距离测量和运动检测, 这些特点让超宽带射频在感知领域也得到应用。与 Wi-Fi 和 RFID 等有限带宽的射频模式相比, 超宽带射频的超高带宽带来了细粒度的测距分辨率, 因此具有精度更高的感知能力; 与毫米波和激光这种高频的射频模式相比, 超宽带射频具有更小的传播损耗和更强的穿透能力, 因此在非视线 (Non-Line-of-Sight, NLOS) 场景下有着更鲁棒的感知能力; 换言之, 超宽带射频感知在感知精度和感知鲁棒性上取得了良好的平衡。目前市面上已经有不少基于超宽带射频的商用脉冲超宽带雷达, 本文使用的脉冲超宽带雷达为 XeThru 的 X4 雷达, 该款雷达具有单根发射天线和单根接收天线, 中心频率为 7.29GHz, 带宽为 1.4GHz, 有不少工作使用该雷达去完成了不同的下游感知任务, 例如生命体征监测^[56-57], 空中手写识别^[58], 人类活动识别^[59], 音频振动提取和分离^[60]等。本节后续将详细介绍脉冲超宽带雷达的感知原理以及雷达接收信号的数据结构。

2.1.1 脉冲超宽带雷达感知原理

脉冲超宽带雷达的调制解调流程如图2-1所示, 雷达发射被调制在频率为 f_c 的余弦载波上的高斯脉冲 $g(t)$, 脉冲信号会以间隔 T_s 周期性地发射, 发射信号的数学表示如公式 (2-1) 所示:

$$x(t) = g(t - kT_s) \cos(2\pi f_c(t - kT_s)) \quad (2-1)$$

高斯脉冲信号 $g(t)$ 可以表示为公式 (2-2):

$$g(t) = V_{tx} \exp(-2\pi^2 f_B^2 \log_{10}(e) t^2) \quad (2-2)$$

式中: f_B ——-10dB 带宽; V_{tx} ——高斯脉冲的最大幅值。雷达发射的信号被环境中的物体反射并由接收天线接收, 通常, 发射天线和接收天线会被雷达集成到同一位置上。由于感知范围内存在着不同的反射物体, 因此信道响应 $h(t)$ 可以表示为具有不同时延和衰减的 P 条路径的总和, 如公式 (2-3) 所示:




图 2-1 脉冲超宽带雷达的调制解调流程

$$h(t) = \sum_{p=1}^P \alpha_p \delta(t - T_p) \quad (2-3)$$

式中： T_p ——反射路径距离决定的往返飞行时间； $\delta(t)$ ——单位冲激函数； α_p ——该反射路径固有的反射强度系数。那么接收天线接收到的信号 $y(t)$ 就可以被建模成发射信号与信道脉冲响应的卷积再加上噪声 $n(t)$ ，如公式 (2-4) 所示：

$$\begin{aligned} y(t) &= x(t) * h(t) + n(t) \\ &= \sum_{p=1}^P \alpha_p g(t - kT_s - T_p) \times \cos(2\pi f_c(t - kT_s - T_p)) + n(t) \end{aligned} \quad (2-4)$$

在接收侧，会对接收信号 $y(t)$ 进行下变频操作，具体操作为将 $y(t)$ 在混频器中与载波余弦及正弦信号相乘，再通过低通滤波器（Low-Pass Filter, LPF），分别得到 I 路信号（In-phase Signal）和 Q 路信号（Quadrature Signal），对于 I 路信号，将 $y(t)$ 与余弦载波 $\cos(2\pi f_c(t - kT_s))$ 相乘后，仅考虑余弦部分，如公式 (2-5) 所示：

$$\begin{aligned} m(t) &= \cos(2\pi f_c(t - kT_s - T_p)) \times \cos(2\pi f_c(t - kT_s)) \\ &= \frac{1}{2} \left[\cos\left(2\pi 2f_c\left(t - kT_s - \frac{T_p}{2}\right)\right) + \cos(2\pi f_c T_p) \right] \end{aligned} \quad (2-5)$$

由于 $2f_c$ 频率分量会被低通滤波器滤除，因此只有低频分量 $\frac{1}{2} \cos(2\pi f_c T_p)$ 被留下，因此，在经过下变频和滤波器后的 I 路信号如公式 (2-6) 所示：

$$\begin{aligned}
y_{\text{in-phase}}(t) &= LPF[y(t) \cdot \cos(2\pi f_c(t - kT_s))] \\
&= \frac{1}{2} \sum_{p=1}^P \alpha_p g(t - kT_s - T_p) \times \cos(2\pi f_c T_p) + n(t)
\end{aligned} \tag{2-6}$$

同理，也可以得到 Q 路信号，如公式 (2-7) 所示：

$$\begin{aligned}
y_{\text{quad}}(t) &= LPF[y(t) \cdot \sin(2\pi f_c(t - kT_s))] \\
&= \frac{1}{2} \sum_{p=1}^P \alpha_p g(t - kT_s - T_p) \times \sin(2\pi f_c T_p) + n(t)
\end{aligned} \tag{2-7}$$

在数字信号处理领域，I 路信号和 Q 路信号通常一起组成复数信号，那么根据欧拉公式，可以对复数形式的接收信号 $y_{\text{complex}}(t)$ 进行推导，如公式 (2-8) 所示：

$$\begin{aligned}
y_{\text{complex}}(t) &= y_{\text{in-phase}}(t) + j \cdot y_{\text{quad}} \\
&= \frac{1}{2} \sum_{p=1}^P \alpha_p g(t - kT_s - T_p) \times [\cos(2\pi f_c T_p) + j \cdot \sin(2\pi f_c T_p)] + n(t) \\
&= \sum_{p=1}^P A_p \cdot e^{j\theta_p} + n(t)
\end{aligned} \tag{2-8}$$

从复数形式的接收信号上，可以很直观地看出，最终的接收信号其实是多个路径的复数反射信号以及噪声的叠加，路径 p 对应的复数反射信号的幅值 A_p 为 $\frac{1}{2}\alpha_p g(t - kT_s - T_p)$ ，相位 θ_p 为 $2\pi f_c T_p$ 。至此，完成了对脉冲超宽带雷达接收信号的数学推导。

2.1.2 脉冲超宽带雷达数据结构

在上一小节中完成了对脉冲超宽带雷达从发射信号到接收信号做了严格的数学推导，下面对雷达接收信号的最终数据结构以及对应的物理意义进行分析。上一小节提到，雷达会以 T_s 为周期持续发射脉冲信号，将从一个脉冲发射开始到该脉冲对应最后一个响应到达结束期间采样到的数据称为一帧（Frame）。在一帧内，时间 t 的概念对应于脉冲信号的飞行时间，因此称之为快时间。雷达连续发射脉冲，所有帧按照时间顺序排序，因此，每一帧可以看做是在更慢时间尺度上的采样，将其称之为慢时间，通常，快时间的尺度为数十皮秒，而慢时间的尺度为数百微秒。如果将连续接收到的帧按时间顺序排列起来，那么可以得到一个二维矩阵，如图2-2所示。

连续帧沿 Y 轴（慢时间）排列，在 X 轴（快时间）上，不同采样点的信号对应着不同时间延迟的反射脉冲响应。由于快时间表示脉冲的往返飞行时间，因此，可以将快时间转换成对应的距离，习惯上，将一个固定的快时间采样点称为一个距离箱。假如待感知物体处于不同的距离下，那么可以通过挑选特定的距离箱来将待感知物体对应的




图 2-2 二维雷达信号矩阵示意图

反射信号分离出来，如果物体是动态的，那么可以在连续帧上选择特定距离箱内的信号组成时序信号，从该时序信号中可以提取出物体的运动信息。一个真实的脉冲超宽带雷达的接收数据二维矩阵如图2-3所示，沿着横轴可以切分出单个雷达帧的信号序列，沿着纵轴可以切分出单个距离箱的信号序列。

综上所述，脉冲超宽带雷达在一段连续时间内采集的接收信号数据是一个二维的复数矩阵，矩阵的横轴排列着不同的距离箱，纵轴则排列着该距离箱在不同慢时间采样点上的复数信号。当需要感知特定距离上的物体时，可以挑选出物体所在的距离箱，持续跟踪该距离箱上复数信号的时序变化，一般来讲，物体的反射信号会跨越多个距离箱，此时需要同时跟踪多个距离箱的复数信号。

2.2 迁移学习

到目前为止，深度学习技术已经取得了显著成功，并在诸多实际应用中展现出卓越的性能，但在应对现实场景中的某些特殊需求时仍存在局限性。传统深度学习范式通常基于两个理想假设：一是存在充足的标注训练样本，二是训练数据与测试数据具有同分布特性。然而在实际应用中，获取充足的训练数据往往面临标注成本高昂、数据采集周期漫长，甚至存在现实条件不可行等困境，本文的基于超宽带虚拟阵列的物体三维点云重建方法是基于深度学习技术的，同样面临着上述训练数据采集标注困难的问题。

迁移学习（Transfer Learning）是上述问题的一个有效解决方法。迁移学习的目的是通过迁移不同但相关的源域中的知识来提高深度学习网络模型在目标域上的表现，通过这种方式，可以减少神经网络模型对大量目标域数据的依赖性。关于迁移学习的一般定义为：迁移学习通过源域 $\mathcal{D}_s = (\mathcal{X}_s, P_s(X))$ 的知识迁移来优化目标域 $\mathcal{D}_t = (\mathcal{X}_t, P_t(X))$ 的任务 $\mathcal{T}_t = (\mathcal{Y}_t, f_t)$ ，其中 $\mathcal{D}_s \neq \mathcal{D}_t$ 或者 $\mathcal{T}_s \neq \mathcal{T}_t$ ，即存在域差异或者存在任务差异。一




图 2-3 真实雷达信号数据幅值热图

个典型的迁移学习场景如图2-4所示，图中展示了迁移学习在跨领域图像分类任务中的应用，源域包含了大量带标注的真实图像，首先在源域上预训练出性能良好的图像分类器，之后将模型权重迁移到卡通风格图像的目标域上，由于源域和目标域极其相关，因此分类器在源域上学习到的知识在目标域上很大程度上同样适用，借助于这种知识复用，仅需将预训练模型在目标域上简单微调就能得到良好的性能表现。

迁移学习可以分为三种主要类型^[61]：直推式迁移学习（Transductive Transfer Learning）、归纳式迁移学习（Inductive Transfer Learning）和无监督迁移学习（Unsupervised Transfer Learning）。这三种类别迁移学习的差异在于源域和目标域标注数据的可见性，当仅有源域的标注数据可见时，该场景被归类为直推式迁移学习；当目标域中的标注数据也可见时，则被归类为归纳式迁移学习；当源域和目标域的标注数据都不可见时，归类为无监督迁移学习。本文关注归纳式迁移学习，即源域和目标域的标注数据都可见，在这种场景下，迁移学习的训练过程涉及最初在大型数据集上训练基线模型，之后使用较小的目标数据集对其进行微调（Finetune）来达到最佳性能，而并不是直接在相对有限的目标数据集上训练模型，这种训练模式也被称为迁移学习中的“预训练（Pretrain）-微调（Finetune）”两阶段学习范式。先前实验的经验证据表明，通过这种两阶段学习，迁移学习能够有效地对抗过拟合，加快训练，并尤其降低了在目标域上训练时所需的数据集大小^[62]。

近年来，迁移学习已经被广泛应用于各领域的深度学习任务中，在医学影像分类领域中，Kathamuthu 等人^[63]提出了使用迁移学习增强的 CNN 框架模型，用于使用 CT 扫描图像检测 COVID-19，在最小的数据集上仍能有效检测 COVID-19 的存在；在机械故障诊断领域，文献^[64]提出了一种基于区块链的分散联邦迁移学习方法，有效缓解了




图 2-4 迁移学习示意图

单个工业用户数据质量和数量的局限性；在遥感领域，Gomroki 等人^[65]提出了一种半迁移学习方法，成功提升了网络模型在城市土地覆盖变更检测任务上的性能表现；在近年来最火热的大语言模型（Large Language Model, LLM）领域，迁移学习同样应用广泛，低秩适配（Low-rank adaptation, Lora）^[66]技术作为大模型时代迁移学习的关键技术突破，通过矩阵分解策略在参数效率与知识保留间取得平衡，大大降低了大语言模型微调的训练成本。

2.3 本章小结

本章对本文所使涉及到的相关理论和技术进行了详细的介绍。首先介绍了脉冲超宽带雷达感知技术，其中包括脉冲超宽带雷达感知原理以及对应的雷达数据结构；接着介绍了迁移学习的基本定义，用于解决的问题以及在各个领域的应用情况。

3 基于信号多视角逆投影融合的三维点云重建方法

3.1 引言

物体三维重建一直作为一个重要的研究领域，其目的在于利用各种类型的输入来恢复出物体的三维结构，例如点云、网格和体素等。然而，目前的物体三维重建领域的主流研究方向是基于二维 RGB 图像的三维重建，该类方法的缺陷在于极其依赖场景的可见性和光照条件，在存在遮挡和光照环境恶劣的情况下，该类方法将不再适用。也有部分研究人员使用射频传感器来进行物体三维重建，这类方法不依赖于环境光照，并且由于射频的穿透能力可以有效地解决遮挡问题，但其中大部分方法依赖于集成了多根发射天线和多根接收天线的复杂且昂贵的射频设备，并且大部分工作聚焦于恢复人体这一较为简单固定的形状模式，对于普适的物体形状并不适用。

本章将介绍本文的第一个主要贡献点，即提出了一种基于信号多视角逆投影融合的三维点云重建方法。该方法利用物体的移动为单发单收的超宽带雷达等效出大量的虚拟天线，构建虚拟天线阵列，大幅提升了超宽带雷达的感知能力。之后基于雷达接受信号的物理建模，通过减去参考信号的方式对雷达信号的背景反射进行了消减；同时，基于目标信号的能量分布特征，设计了有效距离箱定位算法，利用滑动窗口的思想裁剪出有效的目标信号。随后，本章通过分析当物体位置发生微小偏移时对雷达信号的影响，设计了虚拟天线偏移和相位旋转两种数据增强方法，有效地提升了数据集的多样性。接着，本章设计了三维重建神经网络模型，该模型以物体多视角下的复数信号矩阵作为输入，输出物体多视角下的预测深度图，并最终通过深度图逆投影和点云融合得到重建点云。本章实验结果表明，该三维点云重建方法取得了足够高的性能表现，同时在物体被完全遮挡的情况下仍能保持一个较高的性能；实验结果同样表明本章的数据增强算法对网络模型的性能产生了较大的提升。

3.2 超宽带雷达信号采集与处理

3.2.1 超宽带虚拟天线阵列构建

使用仅具有单根发射天线和单根接收天线的超宽带雷达去进行物体三维重建是极具挑战性的，原因在于：（1）超宽带雷达使用的射频信号波长较大，因此感知分辨率相较于 RGB 相机甚至是毫米波雷达都远远不足；（2）大多数雷达系统为了提升雷达感知能力，通常会集成多根发射天线（ T 根）和多根接收天线（ R 根）去等效出 $T \times R$ 根虚拟天线来提升雷达分辨率，而单发单收的超宽带雷达不具备这样的能力。因此，想要使用单发单收的超宽带雷达来进行物体的三维重建，必须要提升雷达的感知能力。

受到逆合成孔径雷达（Inverse Synthetic Aperture Radar, ISAR）的启发，本文通过使被重建物体相对于雷达运动起来，来生成大量的虚拟雷达天线，从而提升雷达的感

知能力。首先介绍一下被人们熟知的合成孔径雷达（Synthetic Aperture Radar, SAR），SAR 是一种利用雷达平台的运动来合成更大孔径雷达天线的技术，SAR 系统一般被安装在移动平台上例如飞机、卫星等，平台沿着预定路径移动，在移动过程中，雷达连续发射脉冲信号并接收回波信号，在每一个雷达发射脉冲信号的位置都可以等效出一个虚拟雷达天线，通过这种方式，可以模拟出一个大的虚拟天线孔径，大大提升雷达的感知分辨率。ISAR 和 SAR 的原理相似，ISAR 也是利用雷达和物体之间的相对运动来合成更大孔径雷达天线，不同之处在于 ISAR 是通过物体自身运动来产生这种相对运动，因此被称为逆合成孔径雷达。本文利用 ISAR 的原理，让物体相对于超宽带雷达运动起来，这种运动又可以等效为雷达相对于物体的运动，在雷达每一次发射超宽带脉冲信号的位置都可以等效出一个超宽带虚拟天线，物体的一次持续运动可以产生巨量的虚拟天线构成一个虚拟阵列，原理如图3-1所示。让物体相对雷达运动起来看似是一个比较严苛的条件，然而在物流、安检等场景下，物体是需要被放置在传送带上进行运输的，此时，只需将雷达系统安装在传送带侧边，就可以让物体相对于雷达产生稳定匀速的相对运动，本文提出的三维点云重建方法恰好也是针对物流、安检这些物体有可能被轻薄包装包裹的场景。




图 3-1 虚拟天线阵列构建示意图

经过超宽带虚拟天线阵列构建后，超宽带雷达接收到的二维矩阵信号的物理意义发生了一些改变。根据章节2.1.2中介绍，在一段连续时间内，超宽带雷达采集到的数据为一个二维复数矩阵，矩阵的慢时间轴代表着不同的采样帧，快时间轴代表着不同的距离箱。当雷达和物体相对运动时，由于每个帧的时间极短（数百微秒），帧内位移极小，因此可以认为在一个帧内，雷达和物体是相对静止的，进而可以认为，雷达在一个帧内不同快时间上的采样其实是一个虚拟天线在固定位置上对不同快时间的采样。因此，此时二维矩阵的慢时间维度意义发生改变，慢时间维度对应的是不同的虚拟超宽带天线。

综上所述，本文通过物体和雷达之间的相对运动来为雷达构建出大量的虚拟天线组成大型超宽带虚拟阵列，来大幅提升超宽带雷达的感知能力，超宽带雷达接收到的

二维矩阵信号，慢时间轴对应的是不同的虚拟天线，快时间轴对应的是不同的距离箱。同时，由于仅从单一视角去用上述方法采集信号，很难获取到物体侧面及背面的几何结构信息，因此，本文会从物体的四个不同视角使用上述方法去进行信号的采集，最终，采集到的四个二维复数矩阵会送入后续的处理流程。

3.2.2 背景反射消减

由于超宽带雷达不仅会被目标物体所反射，也会被环境中的其他非目标物体所反射，雷达最终得到的接收信号里实际也包含了这部分信号，会对目标信号产生干扰，同时，由于发射天线和接收天线之间的串扰（Crosstalks），即发射天线到接收天线之间的直接信号泄露，会导致每个接收帧的前几个距离箱的信号幅值异常强烈。这两种干扰会影响对目标信号的定位和后续处理产生影响，本文将这两种干扰信号统称为背景反射。为了避免背景反射对目标信号的影响，需要对这部分发射进行消减。

回顾第二章对接收信号的基础建模，可以将接收信号再进一步细化，如公式 (3-1) 所示：

$$\begin{aligned}
 y(t) &= \sum_{p_target=1}^{P_target} A_{p_target} \cdot e^{j\theta_{p_target}} \\
 &+ \sum_{p_other=1}^{P_other} A_{p_other} \cdot e^{j\theta_{p_other}} + y_{crosstalks}(t) + n(t) \\
 &= y_{target}(t) + y_{other}(t) + y_{crosstalks}(t) + n(t)
 \end{aligned} \tag{3-1}$$

式中： $y(t)$ ——接受信号； $y_{target}(t)$ ——目标物体反射信号； $y_{other}(t)$ ——其他非目标物体的干扰反射信号； $y_{crosstalks}(t)$ ——串扰产生的干扰信号， $n(t)$ ——高斯电磁噪声。由于最终接受信号是四部分信号的简单线性叠加，高斯电磁噪声由于信号幅值数量级较小可以做忽略，因此只需要得到两部分干扰信号的估计值，便可以通过线性相减来得到目标信号的估计值。考虑到在信号采集过程中，背景环境是相对静止的，同样的，串扰产生的干扰信号也是保持稳定的，因此，可以在目标物体尚未出现在感知区域时，采集一组参考信号 $y_{ref}(t)$ ，该参考信号可以看做是 $y_{other}(t)$ 和 $y_{crosstalks}(t)$ 叠加的估计值，通过对接收信号做线性相减，可以得到目标信号的估计值，如公式 (3-2) 所示：

$$\begin{aligned}
 \hat{y}_{target}(t) &\approx y(t) - [y_{other}(t) + y_{crosstalks}(t)] \\
 &\approx y(t) - [\hat{y}_{other}(t) + \hat{y}_{crosstalks}(t)] \\
 &= y(t) - y_{ref}(t)
 \end{aligned} \tag{3-2}$$

背景反射消减前后的信号对比如图3-2所示，图3-2(a)为未进行背景反射消减的初始雷达信号，图3-2(b)为消减背景反射后的雷达信号，从图中可以明显看出通过上述的背景反射消减方法，成功消除了串扰导致的前几个距离箱的异常高信号幅值，同时，由于去除了背景物体的发射信号的干扰，目标物体的反射信号更加清晰可见。




图 3-2 背景反射消减前后对比

3.2.3 有效距离箱定位

在上一小节中，本文对雷达接收信号进行了背景反射消除，得到了目标信号，从图3-2(b)中可以清楚看到，目标信号的能量大部分分布在较集中的几个距离箱内，其余大多数距离箱的信号幅值接近于零，说明目标物体的有效信号处在这几个集中的距离箱中，本小节探究如何精准定位这些距离箱。

首先，对每个距离箱的距离分辨率做理论上的推导。本文使用的脉冲超宽带雷达的采样率为 23.328GHz，在雷达接收器测，对接收信号做下变频后会对最终的数字信号进行 8 倍的下采样，因此，实际的采样率会减少 8 倍，可以计算出基带数据中相邻距离箱之间的距离差，如公式 (3-3) 所示：

$$\begin{aligned}
 \Delta d &= \frac{c}{2 \times f_s} \\
 &= \frac{2.998 \times 10^8 \text{m/s}}{2 \times 23.328 \times 10^9 / 8 \text{Hz}} \\
 &= 0.0514 \text{m}
 \end{aligned} \tag{3-3}$$

式中： Δd ——相邻距离箱之间距离差； c ——光速； f_s ——实际采样率。通过上面的理论计算，可以得出雷达数据相邻距离箱的理论距离差为 5cm 左右，但实际上，这并不意味着 5cm 范围内的反射物体只会影响单个距离箱的反射信号。考虑到脉冲超宽带雷达发射的脉冲信号并不是一个理想的狄拉克函数，而是一个有脉冲宽度的高斯脉冲，该脉冲的基带信号如图3-3(a)所示，经过载波调制后的信号则如图3-3(b)所示。高斯脉冲在时间上的脉冲宽度会导致，即使对于一个理想的反射点来说，它的反射信号也会扩散到目标距离箱相邻两侧的距离箱内。由于高斯脉冲在距离箱上的扩散效果以及物体的实际尺寸在与雷达的径向方向上大于 5cm，物体最终的反射信号会跨越多个距离箱，在观察大量实际采集到的雷达信号，以及参考其他工作的经验^[56-57]，本文认为，有效的物体反射信号不会跨越超过 9 个距离箱，因此只需定位包含有效信号的 9 个距离箱，其余距离箱的信号可以丢弃，避免后续处理过程中额外的运算量。




图 3-3 载波调制前后的高斯脉冲, $f_c = 7.29\text{GHz}$, $\text{BW} = 1.4\text{GHz}$

由于高斯脉冲信号的能量集中分布在脉冲峰值附近, 同时目标物体在空间上的分布也较为集中, 因此, 有效信号所处的距离箱应该都具有较高的信号幅值, 并且呈现从中间距离箱向两边距离箱衰减的趋势, 如图3-2(b)中所示。根据有效信号幅值在距离箱上的分布特点, 本文使用算法3-1来提取出有效距离箱。该算法的输入为进行过背景反射消减的雷达信号, 是一个二维复数数组, 两个维度分别为帧数和距离箱数, 算法中使用滑动窗口的思想去寻找信号幅值和最大的 9 个连续距离箱, 将最终寻找到的 9 个连续距离箱裁剪出来, 认为是目标物体反射的有效距离箱, 裁剪后的信号如图3-4所示。




图 3-4 有效距离箱定位及裁剪

算法 3-1 有效距离箱定位算法**输入:** 二维复数信号矩阵 $\mathbf{S}$ (帧数 $\times$ 距离箱数)**输出:** 裁剪后的有效距离箱信号 $\mathbf{S}'$

```

1:  $\mathbf{A} \leftarrow |\mathbf{S}|$  ▷ 计算信号幅度矩阵
2:  $N_{fr} \leftarrow \dim_1(\mathbf{S})$  ▷ 总帧数
3:  $N_{rb} \leftarrow \dim_2(\mathbf{S})$  ▷ 总距离箱数
4:  $W_{sz} \leftarrow 9$  ▷ 滑动窗口尺寸
5: 初始化滑动窗口边界
6:  $w_l \leftarrow 0$  ▷ 窗口左边界
7:  $w_r \leftarrow W_{sz} - 1$  ▷ 窗口右边界
8:  $\Gamma_{max} \leftarrow \sum \mathbf{A}[:, w_l : w_r + 1]$  ▷ 初始窗口能量
9:  $\Gamma_{tmp} \leftarrow \Gamma_{max}$ 
10:  $w_l^{opt} \leftarrow w_l, w_r^{opt} \leftarrow w_r$  ▷ 最优窗口边界
11: 滑动窗口能量最大化
12: while  $w_r < N_{rb} - 1$  do
13:    $w_r \leftarrow w_r + 1$  ▷ 窗口右移
14:    $\Gamma_{tmp} \leftarrow \Gamma_{tmp} + \sum \mathbf{A}[:, w_r]$ 
15:    $\Gamma_{tmp} \leftarrow \Gamma_{tmp} - \sum \mathbf{A}[:, w_l]$ 
16:    $w_l \leftarrow w_l + 1$ 
17:   if  $\Gamma_{tmp} > \Gamma_{max}$  then
18:      $\Gamma_{max} \leftarrow \Gamma_{tmp}$ 
19:      $w_l^{opt} \leftarrow w_l$ 
20:      $w_r^{opt} \leftarrow w_r$ 
21:   end if
22: end while
23:  $\mathbf{S}' \leftarrow \mathbf{S}[:, w_l^{opt} : w_r^{opt} + 1]$ 

```

3.3 雷达信号数据增强

在基于深度学习的三维物体重建方法中，数据质量和数量直接决定了神经网络模型的泛化能力和重建精度。然而，由于本文的超宽带虚拟阵列构建方法使得每组雷达信号的采集都较为繁琐耗时，因此雷达信号数据集面临着数据采集成本高，数据样本单一的问题，数据增强技术作为缓解数据不足、提升模型鲁棒性的核心手段，通过生成多样化的合成数据，能够在有限的原始数据基础上扩展训练集，从而减少过拟合风险并增强模型对复杂场景的适应性。因此，在将提取到的有效雷达信号输入到深度学习神经网络中进行训练前，本文对雷达信号进行数据增强，提升数据集中数据的多样性。

首先分析雷达信号数据集中数据单一性产生的原因。回顾超宽带虚拟阵列构建的方法，通过物体相对于雷达的运动，等效出虚拟天线，物体运动过程中，雷达不断收发信号，接收到的一组信号可以等效为多个虚拟天线接收到的信号，然而在这一过程中，当物体的初始放置位置发生一些微小位移，最终接收到的信号会发生明显的变化，在数据集采集过程中，很难对物体的所有可能初始位置进行遍历，这也就造成了数据集中样本的单一，幸运的是，可以通过数据增强的方法从一个原始数据合成出物体初始位置发生位移时对应的其他雷达信号数据。

由于物体放置平台与雷达的高度是固定的，因此物体初始位置只会在放置平台所处平面的两个维度上发生微小位移，即沿物体运动方向和垂直物体运动方向，本文通过分析当物体初始位置在两个维度上发生微小位移时对应雷达信号的变化，设计出针对这两种情况下的数据增强方法，即虚拟天线偏移（Virtual Antenna Shift, VAS）和相位旋转（Phase Rotation, PR）。

3.3.1 虚拟天线偏移数据增强

当物体初始位置沿物体运动方向发生正负位移时，如图3-5所示，即物体初始位置沿 x 轴发生位移，假设每条雷达信号的帧数相同，即等效出的虚拟天线数相同，那么当物体初始位置沿 x 轴正方向发生位移时，根据物体和雷达的相对运动，可以等效为所有的虚拟天线位置沿 x 轴负方向发生了位移；同理，当物体初始位置沿 x 轴负方向发生位移时，可以等效为所有的虚拟天线位置沿 y 轴正方向发生了位移。因此，针对物体初始位置沿运动方向发生微小偏移的情况，本文使用虚拟天线偏移的方法来进行数据增强。在对雷达信号进行采集时，可以适当增大每条雷达数据的帧个数，即适当增大等效出的虚拟天线个数，之后对雷达信号矩阵沿帧方向进行固定长度的随机裁剪，来模拟虚拟天线在 y 轴上发生偏移，具体的，本文在对物体进行信号采集时，稍微增加物体的运动长度，让每条雷达信号的帧长度保持在 3000 左右，之后以 2800 帧的固定长度对雷达信号矩阵进行随机裁剪，产生多条雷达信号数据，对应物体初始位置沿物体运动方向发生正负位移时的信号。




图 3-5 物体初始位置沿物体运动方向发生微小位移

3.3.2 相位旋转数据增强

1) 理论分析

当物体初始位置沿垂直物体运动方向发生位移时，如图3-6所示，由于物体到每个虚拟天线的径向距离都发生变化，因此每个虚拟天线采集到的复数信号均发生改变，情况相对更复杂。首先理论分析当物体初始位置沿垂直物体运动方向偏移时，各虚拟天




图 3-6 物体初始位置沿垂直物体运动方向发生微小位移

线接收信号的变化，回忆对接收信号的数学建模，如公式 (3-4) 所示：

$$y(t) = \sum_{p=1}^P A_p \cdot e^{j\theta_p} + n(t) \quad (3-4)$$

接收信号是多个反射路径的反射信号的叠加，对于复数信号矩阵，选定某一个固定虚拟天线 ant 和距离箱 bin ，仅考虑路径 p 的反射信号 $y_p(\text{ant}, \text{bin})$ ，那么对应的幅值 $A_p(\text{ant}, \text{bin}) = \frac{1}{2}\alpha_p g(t_{\text{bin}} - T_p)$ ，相位 $\theta_p(\text{ant}, \text{bin}) = 2\pi f_c T_p$ ，其中， α_p 为该反射路径的固有反射强度系数， t_{bin} 为该距离箱对应的快时间采样时间， T_p 为该路径的信号往返时延，如果物体初始位置沿垂直物体运动方向发生微小位移，那么相当于所有反射路径变长，相应的，信号在该路径上的往返时延也发生了变化，即 $T'_p = T_p + \Delta T$ ，考虑该变化对信号幅值和相位的分别影响，假设物体与虚拟天线距离变化为 $\Delta d = 1\text{cm}$ ，对应的 $\Delta T = \frac{2\Delta d}{c}$ 则为 0.067ns ，对于信号幅值， α_p 项是反射路径的固有反射强度系数，几乎不受微小位移影响， $g(t_{\text{bin}} - T_p)$ 受 ΔT 影响，但 $g(t)$ 对应的高斯脉冲的脉冲宽度约为 2ns ，远大于 ΔT 的值，因此， ΔT 对 $g(t_{\text{bin}} - T_p)$ 函数值的影响也可以忽略不计，于是有：

$$\begin{aligned} A'_p(\text{ant}, \text{bin}) &= \frac{1}{2}\alpha_p g(t_{\text{bin}} - (T_p + \Delta T)) \\ &\approx \frac{1}{2}\alpha_p g(t_{\text{bin}} - T_p) \\ &= A_p(\text{ant}, \text{bin}) \end{aligned} \quad (3-5)$$

即物体的微小位移几乎不改变信号幅值。对于信号相位的变化量，如公式 (3-6) 所示：

$$\begin{aligned}\Delta\theta_p(\text{ant}, \text{bin}) &= \theta'_p(\text{ant}, \text{bin}) - \theta_p(\text{ant}, \text{bin}) \\ &= 2\pi f_c(T_p + \Delta T) - 2\pi f_c T_p \\ &= 2\pi f_c \Delta T\end{aligned}\quad (3-6)$$

当距离变化为 1cm 时，带入 $f_c = 7.29\text{GHz}$ ，可以得到 $\Delta\theta_p(\text{ant}, \text{bin}) = 3.07$ ，这对于相位来说是一个极大的改变。考虑多个路径信号叠加后的信号，忽略噪声项，如公式 (3-7) 所示：

$$\begin{aligned}y'(\text{ant}, \text{bin}) &= \sum_{p=1}^P A'_p(\text{ant}, \text{bin}) \cdot e^{j\theta'_p(\text{ant}, \text{bin})} \\ &\approx \sum_{p=1}^P A_p(\text{ant}, \text{bin}) \cdot e^{j(\theta_p(\text{ant}, \text{bin}) + \Delta\theta_p(\text{ant}, \text{bin}))} \\ &= e^{j\Delta\theta_p(\text{ant}, \text{bin})} \cdot \sum_{p=1}^P A_p(\text{ant}, \text{bin}) \cdot e^{j\theta_p(\text{ant}, \text{bin})} \\ &= e^{j\Delta\theta_p(\text{ant}, \text{bin})} \cdot y(\text{ant}, \text{bin})\end{aligned}\quad (3-7)$$

结论为，当物体初始位置在垂直物体运动方向发生微小位移后，某个固定虚拟天线的接收信号会有一个相位旋转，旋转的相位与位移成正比。接下来需要考虑，对于多个虚拟天线，该相位旋转是否保持一致。考虑物体在垂直物体运动方向位移对于物体与虚拟天线距离的影响，物体和虚拟天线的水平距离为 x ，垂直距离为 y ，则欧式距离为 $d = \sqrt{x^2 + y^2}$ ，假设物体在垂直方向的位移为 Δy ，该值相对于 y 是一个极小值，因此可以通过一阶泰勒展开并忽略高阶余项来求欧式距离变化量的近似值，如公式 (3-8) 所示：

$$\begin{aligned}\Delta d &= \sqrt{x^2 + (y + \Delta y)^2} - \sqrt{x^2 + y^2} \\ &\approx \Delta y \cdot \sqrt{x^2 + y^2}' \\ &= \Delta y \cdot y \cdot (x^2 + y^2)^{-\frac{1}{2}} \\ &= \Delta y \cdot \frac{1}{\sqrt{\left(\frac{x}{y}\right)^2 + 1}}\end{aligned}\quad (3-8)$$

本文的实验设置中， $0 < \frac{x}{y} < \frac{1}{2}$ ，因此 $1 > \frac{1}{\sqrt{\left(\frac{x}{y}\right)^2 + 1}} > 0.894$ ，即 $\Delta y > \Delta d > 0.894\Delta y$ ，即对于所有虚拟天线来说， Δd 可以看做是近似相等，对应 ΔT_p 也可以看做是近似相等，对信号相位的旋转也可以近似为相等。

综上所述，当物体的初始位置在垂直物体运动方向发生微小位移后，会对虚拟天线接收到的信号产生相位上的旋转，而几乎不影响信号的幅值，并且对于所有虚拟天

线来说信号相位的旋转程度近似相等，因此，可以通过为初始复数雷达信号矩阵每个元素添加相同的相位旋转来合成物体初始位置在垂直方向位移后的数据。

2) 验证性实验

针对上述理论分析，本文通过实验来对理论的正确性进行了验证。本文选择了一个固定的目标物体，该物体相对于雷达匀速运动，采集了多组雷达信号，在每组实验中，雷达与物体在垂直方向上的距离以 0.5cm 为步长逐渐改变。多组实验对应的信号矩阵的信号幅值热图如图3-7所示，从图中可以看出，多组实验的信号矩阵幅值非常相似，切分出其中一个距离箱的信号，绘制出多组实验中雷达信号对应的幅值和相位，




图 3-7 各组实验下雷达信号幅值热图，横轴为距离箱，纵轴为虚拟天线

如图3-8(a)和图3-8(b)所示，从图中可以清晰看出，当雷达和物体的垂直方向距离微小改变时，各虚拟天线上的信号幅值基本保持一致，而相位发生旋转，同时各虚拟天线上的相位旋转程度基本保持一致，与上文中的理论分析相吻合。




图 3-8 各组实验下某个距离箱内不同虚拟天线对应信号的幅值图与相位图

3.3.3 数据增强算法

通过上述两种数据增强方法，可以分别合成出物体初始位置在水平方向和垂直方向发生微小位移时对应的雷达信号数据，因此结合两种方法，可以合成出物体在二维平面任意方向上发生位移时对应的雷达信号数据，本文设计一种数据增强的算法，结合两种数据增强方法，为每组初始数据进行数据增强，见算法3-2。

算法 3-2 数据增强算法

输入:

初始信号数据 $\mathbf{X} \in \mathbb{C}^{4 \times N \times M}$

▷ 视角 × 虚拟天线 × 距离箱

增强系数 $K_1, K_2 \in \mathbb{N}^+$

▷ 虚拟天线偏移/相位旋转增强系数

最大偏移量 $\Delta_{\max} = 80$

输出: 增强后信号数据集 $\tilde{\mathbf{X}} \in \mathbb{C}^{K \times 4 \times T \times M}$

▷ $K = K_1 K_2$

1: $\{\mathcal{P}_i\}_{i=1}^4 \leftarrow \emptyset$

▷ 初始化参数集合

2: **for** $i \leftarrow 1$ **to** 4 **do**

▷ 四个视角

3: **for** $k_1 \leftarrow 1$ **to** K_1 **do**

4: $\delta \leftarrow \mathcal{U}(0, \Delta_{\max})$

▷ 均匀采样虚拟天线偏移量

5: **for** $k_2 \leftarrow 1$ **to** K_2 **do**

6: $\theta \leftarrow \mathcal{U}(0, 2\pi)$

▷ 均匀采样相位旋转量

7: $\mathcal{P}_i \leftarrow \mathcal{P}_i \cup \{(\delta, \theta)\}$

8: **end for**

9: **end for**

10: Shuffle($\mathcal{P}_i$)

▷ 随机化参数顺序

11: **end for**

12: **for** $i \leftarrow 1$ **to** 4 **do**

▷ 四个视角

13: **for** $k \leftarrow 1$ **to** K **do**

14: $(\delta, \theta) \leftarrow \mathcal{P}_i^{(k)}$

▷ 提取参数

15: $\mathbf{X}' \leftarrow \mathbf{X}[i, \delta : \delta + T, :]$

▷ 帧切片

16: $\mathbf{X}'' \leftarrow \mathbf{X}' \odot e^{j\theta}$

▷ 相位旋转

17: $\tilde{\mathbf{X}}[k, i] \leftarrow \mathbf{X}''$

18: **end for**

19: **end for**

该算法的输入为一组初始信号数据 $\mathbf{X} \in \mathbb{C}^{4 \times N \times M}$ ，该组数据包括了 4 个视角下的虚拟天线 × 距离箱 的复数信号矩阵。通过指定增强系数 K_1 （虚拟天线偏移次数）和 K_2 （相位旋转次数），可以设置增强后的样本数 $K = K_1 K_2$ 。算法中首先对每个视角独立生成 $K_1 \times K_2$ 组增强参数，其中虚拟天线偏移量 δ 从均匀分布 $\mathcal{U}(0, \Delta_{\max})$ 中采样，相位旋转角度 θ 从均匀分布 $\mathcal{U}(0, 2\pi)$ 中采样，为了保证 4 个视角的数据进行组合时样本的

随机性，对生成的增强参数顺序进行打乱。之后，根据增强参数对初始数据进行增强操作，即进行帧切片和相位偏转，最终得到增强后的信号数据集 $\tilde{\mathbf{X}} \in \mathbb{C}^{K \times 4 \times T \times M}$ ，包含了增强后的 K 个数据样本。

3.4 三维重建神经网络模型

为了能够从多视角下采集的雷达信号中提取并融合物体的三维结构信息，重建出物体点云，本文设计了三维重建神经网络模型。该网络模型是一个经典的编码器-解码器架构网络模型，模型整体框架如图3-9所示。




图 3-9 三维重建神经网络模型

模型的输入为多个视角下采集到的复数雷达信号矩阵，视角 N 下的复数信号矩阵经过复数信号编码器模块来提取该视角下的物体结构信息对应的隐层特征向量 F_N ，考虑到不同视角下的雷达信号的特征空间是统一的，并且为了避免模型参数数量过大产生的过拟合现象，所有视角使用的复数信号编码器模块都是权重共享的。从多个视角下的雷达信号中提取的隐层特征向量会经过特征拼接来获取全局的特征向量 F_{concat} ，之后输送到解码器模块中。在解码器模块的设计上，首先需要考虑的是模型的输出形式，直观上，很容易想到让模型直接输出 $N \times 3$ 的张量，对应点云中 N 个点的三维坐标，之前也有工作采取了这样的做法^[26]，然而，由于点云是一堆无序点的集合，即使实际点云相同也可能对应不同的点云排列，模型如何在从隐层特征空间向点云张量映射过程中保持点云排列不变性是一个挑战，虽然现有的倒角距离（Chamfer Distance, CD）损失函数和推土机距离（Earth Mover's Distance, EMD）损失函数在理论上满足排列不变性，但在实际应用过程中仍存在着局限性，例如倒角距离损失函数对异常点敏感，每个点只考虑了最近的邻居，容易忽略整体结构；推土机距离损失函数的计算时间复杂度

过高,当点云中点数较多时计算代价过高。另外,使用上述损失函数直接对点云坐标进行回归优化,会导致网络难以捕捉复杂的几何结构,忽略了空间连续性,生成的点云可能会出现不均匀分布或离群点,影响重建质量,因此,本文考虑让网络模型输出多个视角下的深度图 (Depth Map),这些视角的相机参数在采集深度图 Ground Truth 时已经确定,在模型训练阶段,对模型输出的深度图进行回归优化,在测试阶段,根据每个视角的相机参数来对模型输出的深度图进行逆投影得到局部点云,将多个视角的局部点云对齐到同一坐标系后并进行融合得到最终的全局点云。

3.4.1 复数信号编码器模块

从雷达复数信号矩阵中提取出物体的三维结构信息是一个极具挑战性的任务,本文提出了一种基于一维卷积的复数信号编码器模块,有效地从复数信号矩阵中提取出了物体三维结构相关的特征向量。

传统的卷积神经网络针对的是实数形式的输入,无法有效处理复数形式的输入,有些工作使用复数卷积神经网络来处理复数输入^[67-70],然而复数卷积神经网络需要重新定义更复杂的正向传播和反向传播等操作,这也导致复数卷积神经网络训练过程中收敛速度极慢难以训练,同时在性能表现上也并未取得明显的优势;与之相对应的另一种做法是通过将复数输入拆分成两路输入,对应复数的实部和虚部,对两路输入分别做处理,之后将特征进行融合,这种做法在对复数信号使用时具有天然的合理性,因为复数信号的实部和虚部有着真实的物理意义,代表着信号的 I 路和 Q 路,之前的工作对这种方法的有效性进行了验证^[56],相比于复数卷积神经网络,这种做法不破坏原有的卷积神经网络结构,并且具有更好的计算效率和训练稳定性,因此,本文同样采取这种方式。

另一个需要考虑的问题是,模型的输入为 9×2800 的信号矩阵,该输入应该被当做是 9 通道的一维序列使用一维卷积去提取特征,还是当做单通道的 9×2800 二维矩阵使用二维卷积去提取特征。回顾信号矩阵的物理意义,9 对应的是 9 个相邻的距离箱,2800 对应 2800 个虚拟天线,两个维度的物理意义不同,与二维图像两个维度上的相邻像素共同构成空间局部特征并不类似,同时信号矩阵在两个维度上的尺度差异过大,难以设计合理的二维卷积核尺寸,因此,针对该信号矩阵,更合理的做法是将其看做是包含 9 个通道的长度为 2800 的一维序列,使用一维卷积去提取相关特征。复数信号编码器模块的结构如图3-10所示。

通道数为 9,长度为 2800 的复数信号被输入复数编码器模块后,被拆分成相同尺寸的信号实部和信号虚部,作为两路输入,分别输入到两个多尺度一维卷积块 (Multi-scale 1D Conv Block) 中,之后使用逐元素相加的方式来将两路多尺度一维卷积块输出的特征进行融合合并为一路,之后使用 5 级多尺度一维卷积块搭配最大池化 (Max-Pool) 操作来逐步扩大中间特征图的感受野,特征图长度从 2800 缩小到 11,通道数从 32 增长至 512,通过多级的卷积和池化逐步提取输入信号从局部到全局的特征,最后,将多通道特征图铺平至一维,得到长度为 5632 的特征向量,并经过三层全连接 (Fully Connected,




图 3-10 复数编码器模块

FC) 层来对特征向量进行压缩，得到了最终的长度为 128 的特征向量。其中，多尺度一维卷积块是针对本文信号输入以及中间特征图设计的一个卷积模块，设计过程中参考了波束成形算法中的一些思想。波束成形（**Beamforming**）算法是雷达系统中常用的一种算法，其目标在于通过调整虚拟天线阵列的相位和幅值权重，使接收信号在特定方向相干叠加，而一维卷积的过程与之类似，模型训练过程中卷积核的可学习参数相当于动态学习虚拟天线阵列中各天线的加权系数。在波束成形算法中，使用不同数量的相邻虚拟天线对应着不同的空间分辨率，在卷积中使用不同的卷积核可以取得类似的效果，小卷积核模拟窄波束，聚焦局部虚拟天线，大卷积核模拟宽波束，覆盖更广天线范围，因此，在多尺度一维卷积块里，使用了 3,5,7,9 四种尺寸的卷积核，对应不同的空间分辨率，最终将四种卷积核卷积得到的特征图逐元素相加融合输入到激活函数中，为了保证相加时尺寸相同，四种卷积核使用了不同的填充（**Padding**）尺寸，多尺度一维卷积块的结构如图3-11所示。

3.4.2 解码器模块

复数信号编码器模块从多视角下的雷达信号中提取到了包含物体三维结构的特征向量，并将多个视角下的特征向量进行拼接得到了融合之后的特征向量 F_{concat} ，解码器模块则负责从作为中间表示的特征向量 F_{concat} 逐步生成目标的多视角下的深度图输出。

解码器模块的结构如图3-12所示，长度为 512 的 F_{concat} 特征向量输入到解码器后，首先经过三层全连接层来对拼接后的特征向量进行进一步的融合以及升维，特征向量的长度逐步从 512 提升到 4096。由于最终需要得到的是多个视角下的深度图，这是一




图 3-11 多尺寸一维卷积块

个典型的二维结构输出，因此在全连接层之后，对特征向量进行了重新排列，将其组织成了一个 $256 \times 4 \times 4$ 的二维特征图，对应 通道数 $\times$ 高 $\times$ 宽，在之后的计算过程中，需要对该二维特征图进行逐步的特征提取和上采样，将其尺寸逐渐扩展至目标输出尺寸。

对于二维特征图进行特征提取和上采样，最常见的做法是使用反卷积（Transposed Convolution）操作，反卷积操作的核心思想是通过插入零值并应用卷积操作来放大特征图的尺寸，这种操作被广泛应用于语义分割、图像超分辨率和生成对抗网络等任务中，然而，由于反卷积中的插零操作会导致卷积核在覆盖输入时产生不均匀的重叠模式，进而导致反卷积的输出产生棋盘状伪影。与之相对应的另一种做法是通过插值（Interpolation）+ 卷积的操作来替代反卷积操作，相比于插零操作，使用插值来实现的上采样更加平滑，避免了卷积核覆盖时的不均匀重叠，消除了反卷积产生了期盼伪影现象，之后再使用标准卷积操作对特征图进行进一步特征提取，多个工作^[71-72]已经证明了该操作的有效性，因此，本文也使用了这种操作来对特征图进行上采样和特征提取。

在解码器模块中，对于 $256 \times 4 \times 4$ 的二维特征图，通过五层的双线性插值（Bilinear Interpolation）操作搭配二维卷积操作，将特征图尺寸扩展至 $48 \times 128 \times 128$ ，之后，通过最后一层卷积操作得到 $2N \times H \times W$ 的最终输出，该输出的通道数为 $2N$ ， N 对应的是输出视角个数，前 N 个通道的输出对应的是 N 个视角深度图的预测 $D_{\text{pred}} \in \mathbb{R}^{N \times H \times W}$ ，后 N 个通道的输出则是 N 个视角下物体所占据像素的掩膜 $M_{\text{pred}} \in \mathbb{R}^{N \times H \times W}$ ，掩膜的作用在于对物体所处空间位置进行精确预测，排除掉剩余的无用像素点， H 和 W 表示深度图的高度和宽度，本文中均取 128，即输出的深度图的分辨率为 128×128 。为了降低模型的学习难度，本文为深度图输出添加深度先验，具体为，将 Ground Truth 深度图的渲染深度预设深度值偏置，模型输出的预测深度值是相对于该预设深度的偏移量，

因此，模型输出的深度图与预设深度值相加才是最终的深度图预测，通过这种方式，减少了模型预测深度的可能分布空间，有利于模型训练。




图 3-12 解码器模块

3.4.3 损失函数

本小节为上文介绍的神经网络模型设计合理的损失函数，来为模型的训练过程提供合理的优化目标。考虑网络模型的两部分输出，第一部分输出为预测的深度图 $D_{\text{pred}} \in \mathbb{R}^{N \times H \times W}$ ，第二部分输出为物体占据像素的掩膜 $M_{\text{pred}} \in \mathbb{R}^{N \times H \times W}$ ，方便起见，下面只考虑单个视角下损失函数的计算，忽略掉第一个维度。

针对 D_{pred} ，网络模型的优化目标应该是预测深度尽可能接近真实的深度图 D_{gt} ，同时考虑到掩膜外部像素位置的预测深度为无效深度，因此只对掩膜区域的深度值进行约束，可以对掩膜进行二值化，利用二值化后的掩膜与深度值相乘筛选出有效像素点。掩膜的二值化公式如公式 (3-9) 所示：

$$\mathcal{M}(i, j) = \begin{cases} 1, & \text{if } M_{\text{pred}}(i, j) > 0 \\ 0, & \text{otherwise} \end{cases} \quad (3-9)$$

对于预测深度值的约束使用简单的 L1 损失函数就可以实现，对深度值约束的损失函数表达式如公式 (3-10) 所示：

$$\mathcal{L}_{\text{Depth}} = \frac{\sum_{i=1}^H \sum_{j=1}^W \mathcal{M}(i, j) \cdot |D_{\text{pred}}(i, j) - D_{\text{gt}}(i, j)|}{\sum_{i=1}^H \sum_{j=1}^W \mathcal{M}(i, j)} \quad (3-10)$$

针对 M_{pred} ，网络模型的优化目标是使得预测的掩膜和真实的掩膜 M_{gt} 尽可能一致， M_{gt} 是预先处理好的二值化的掩膜，值取 0 或 1，0 表示掩膜区域外，1 表示掩膜区域内，而 M_{pred} 是网络输出的浮点值，本文使用带 Logits 的二元交叉熵损失（Binary Cross-Entropy, BCE）函数来对掩膜进行约束。带 Logits 的 BCE 损失函数通过结合 Sigmoid 激活函数和 BCE 损失，可以直接接受未经过激活函数处理的原始输出，避免了数值不稳定的问题，对掩膜的损失函数表达式如公式 (3-11) 所示：

$$\mathcal{L}_{\text{Mask}} = -\frac{1}{H \cdot W} \sum_{i=1}^H \sum_{j=1}^W \left[M_{\text{gt}}(i, j) \cdot \log \sigma(M_{\text{pred}}(i, j)) + (1 - M_{\text{gt}}(i, j)) \cdot \log (1 - \sigma(M_{\text{pred}}(i, j))) \right] \quad (3-11)$$

式中： σ ——Sigmoid 函数。

网络模型总的损失函数为两部分损失函数的加权和，其表达式如公式 (3-12) 所示：

$$\mathcal{L}_{\text{total}} = \lambda_{\text{Mask}} \cdot \mathcal{L}_{\text{Mask}} + \lambda_{\text{Depth}} \cdot \mathcal{L}_{\text{Depth}} \quad (3-12)$$

式中： λ_{Mask} —— $\mathcal{L}_{\text{Mask}}$ 的权重； λ_{Depth} —— $\mathcal{L}_{\text{Depth}}$ 的权重。

3.5 多视角深度图逆投影及点云融合

上一节中介绍了神经网络模型的输出为多个视角下的深度图预测和对应的物体掩膜，本节探究如何根据上述输出恢复出物体的三维点云。

对于二维深度图中的每一个像素点，可以对其逆投影，计算出该点在相机坐标系下的三维坐标，如公式 (3-13) 所示：

$$\begin{aligned} P_{\text{cam}} &= K^{-1} \cdot P_{\text{img}} \\ &= \begin{bmatrix} \frac{W}{\text{scale}} & 0 & 0 & \frac{W}{2\text{scale}} \\ 0 & -\frac{H}{\text{scale}} & 0 & \frac{H}{2\text{scale}} \\ 0 & 0 & -1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}^{-1} \begin{bmatrix} u \\ v \\ d \\ 1 \end{bmatrix} \end{aligned} \quad (3-13)$$

式中： $P_{\text{cam}} = [x_{\text{cam}}, y_{\text{cam}}, z_{\text{cam}}, 1]^T$ ——该点在相机坐标系下的齐次坐标； $P_{\text{img}} = [u, v, d, 1]^T$ ——该点在像素坐标系下的齐次坐标； u, v ——二维像素网格中点的坐标； d ——该点的深度值； $K \in \mathbb{R}^{4 \times 4}$ ——正交相机内参矩阵的齐次扩展，用于将三维相机坐标系下的点正交投影到二维像素坐标下。因此，在将像素点逆投影到相机坐标系下时，需使用该矩阵的逆矩阵和像素坐标进行矩阵乘法，通过对单个视角的深度图中所有像素点进行

上述逆投影，可以得到该视角下的一系列点云。

解码器模块输出了 N 个视角的深度图预测，这 N 个视角的相机坐标系均不一致，为了对多个视角下深度图逆投影得到的点云进行融合，需要将多个相机坐标系进行统一，即将相机坐标系转换到世界坐标系下。对于第 i 个视角，由相机外参中的旋转四元数 $q_i \in \mathbb{R}^4$ 和平移向量 $t_i \in \mathbb{R}^3$ 可以构建出从世界坐标系到相机坐标系的齐次变换矩阵 $T_i \in \mathbb{R}^{4 \times 4}$ ，如公式 (3-14) 所示

$$T_i = \begin{bmatrix} R_i & t_i \\ \mathbf{0} & 1 \end{bmatrix} \quad (3-14)$$

式中： $R_i \in \mathbb{R}^{3 \times 3}$ ——根据旋转四元数计算得到的旋转矩阵。通过齐次变换矩阵 T_i 可以将世界坐标 P_{world} 转换为相机坐标 P_{cam} ，因此，将相机坐标转换到世界坐标则需要使用该矩阵的逆矩阵进行矩阵乘法，如公式 (3-15) 所示：

$$\begin{aligned} P_{\text{world}} &= T_i^{-1} \cdot P_{\text{cam}} \\ &= \begin{bmatrix} R_i & t_i \\ \mathbf{0} & 1 \end{bmatrix}^{-1} \begin{bmatrix} x_{\text{cam}} \\ y_{\text{cam}} \\ z_{\text{cam}} \\ 1 \end{bmatrix} \end{aligned} \quad (3-15)$$

通过两次矩阵乘法，可以将像素坐标成功转换成世界坐标，但当需要进行转换的像素过多时，两次矩阵乘法的运算成本是较高的，可以事先将两个变换矩阵 K^{-1} 和 T_i^{-1} 进行矩阵相乘得到单个转换矩阵，这样在对每个像素进行三维坐标转换时只需要一次矩阵乘法，大大降低了运算成本，这也是对 K^{-1} 进行齐次扩展的原因，两个变换矩阵合并的过程如公式 (3-16) 所示：

$$\begin{aligned} P_{\text{world}} &= T_i^{-1} \cdot K^{-1} \cdot P_{\text{img}} \\ &= (T_i^{-1} \cdot K^{-1}) \cdot P_{\text{img}} \\ &= R_i \cdot P_{\text{img}} \end{aligned} \quad (3-16)$$

式中： $R_i \in \mathbb{R}^{4 \times 4}$ ——合并之后唯一的变换矩阵。对于齐次世界坐标 P_{world} ，只取其中的前三行元素，可以得到世界坐标系下的三维坐标，通过对第 i 个视角下深度图中所有像素都进行世界坐标转换，可以得到该视角下的局部点云 $PC_i \in \mathbb{R}^{3 \times (H \cdot W)}$ ，此时该局部点云中包含了掩膜外深度图像素转换来的三维坐标点，因此需要使用掩膜来对点云中点进行滤除。网络输出的掩膜 $Mask \in \mathbb{R}^{N \times H \times W}$ 是像素的掩膜，需要将其进行重新排列并进行二值化得到布尔类型的点云的掩膜 $Mask_{\text{pc}} \in \mathbb{B}^{1 \times (H \cdot W)}$ ，通过该掩膜中每个

元素的布尔值对点云中相应位置的点进行保留或删除，这样就得到了第 i 个视角下最终的局部点云，之后，将所有视角下的局部点云合并在一起就得到了最终的全局点云 $PC \in \mathbb{R}^{3 \times M}$ 。至此，通过像素点逆投影以及世界坐标系转换，将神经网络输出的多视角深度图转换成了物体的三维点云。


3.6 实验及结果分析

3.6.1 实验场景布置


本文使用 XeThru 的 X4M05 商用脉冲超宽带雷达进行雷达信号采集，雷达的中心频率为 7.29GHz，带宽为 1.4GHz，雷达帧的生成频率为 40Hz，该雷达仅具有一个发射天线和一个接收天线。为了让物体运动起来为雷达构建虚拟天线，本文将目标物体放置在滑轨的载物台上通过滑轨的运动带动物体运动，通过笔记本电脑同步控制滑轨的运动和雷达的信号采集，构建了一个雷达数据采集平台。

实验场景布置如图3-13(a)所示，雷达与滑轨的垂直距离约为 70cm，同时，为了保证雷达与载物台上物体尽量保持水平高度一致，雷达的水平高度会比载物台高大约 10cm，在一次信号采集过程中，物体放置在载物台上，随着滑轨沿水平方向运动，运动距离大约为 75cm，滑轨运动速度为 1cm/s，因此每次运动时长大约为 75s，乘以雷达帧的生成频率 40Hz，每次运动过程中雷达采集到的帧数大约为 3000 帧。

为了验证本文提出的三维点云重建方法在物体被遮挡情况下的性能表现，本文同样设置了遮挡情况下的信号采集场景，如图3-13(b)所示，物体被放置在载物台上的纸箱之内，物体和雷达之间的视线路径被纸箱所遮挡。



(a) 正常情况下场景图



(b) 物体被遮挡情况下场景图

图 3-13 实验场景布置

3.6.2 数据集采集

为了获取到物体的高精度的三维结构信息作为标注数据，本文收集了有可能出现在物流和安检场景里的共 8 个种类的 48 个物体的三维网格模型文件 (.obj 文件)，并使用这些模型文件进行 3D 打印，得到了真实的物体，如图3-14所示。之后分别在遮挡的情况下和非遮挡情况下使用上文中的雷达数据采集平台对物体的四个视角下的反射信号进行采集，并进行背景反射消减和有效距离箱定位提取出有效信号，之后通过算

法3-2对雷达数据进行了数据增强，最终得到了 9,600 组雷达数据，每组数据中包括 4 个视角下的雷达信号，因此共有 38,400 条雷达数据，每条雷达数据为 2800×9 的复数信号矩阵。



图 3-14 部分 3D 打印的真实物体

为了获取每个物体多视角下的深度图作为网络训练和评估时的 Ground Truth，本文使用开源三维建模工具 Blender（版本 2.78）来对物体的等比例大小三维网格进行深度图渲染，得到了每个物体的高精度多视角深度图 Ground Truth。同时为了评估最终的重建点云的性能表现，本文在物体三维网格上进行了平均采样，得到了致密的真实点云数据。

3.6.3 评估指标

为了全面评估本文提出的三维点云重建方法的性能表现，本文考虑两类数据的精度表现，即网络模型预测的深度图的精度表现以及最终合成出的点云数据的精度表现。

对于深度图的精度表现，本文使用深度图中每个像素点深度值的平均绝对误差来评估，即深度平均绝对误差（Depth Mean Absolute Error, D-MAE），定义如公式 (3-17) 所示：

$$\text{D-MAE} = \frac{1}{N} \sum_{i=1}^N |D_{\text{pred}}(i) - D_{\text{gt}}(i)| \quad (3-17)$$

式中： $D_{\text{pred}}(i)$ ——预测深度图第 i 个有效像素的深度值； $D_{\text{gt}}(i)$ ——真实深度图对应像素的深度值； N ——有效像素总数。为了忽略掉深度图中没有物体出现的无效区域对结果的影响，本文使用网络输出的预测掩膜 M_{pred} 筛选出了有效的像素点。

对于最终合成的点云数据的精度表现，本文采用了两种不同的评估指标。第一个评估指标是重建点云和真实点云（通过对物体三维网格进行平均采样得到的紧密点云）之间的倒角距离（Chamfer Distance, CD）。倒角距离是衡量两个点云相似性的常用指标，其定义为：对于两个点云 $P = \{p_i\}_{i=1}^N$ （重建点云）和 $Q = \{q_j\}_{j=1}^M$ （真实点云），倒角距离的计算分为两部分，（1）对 P 中每个点 p_i ，计算其到 Q 中最近点的距离，并取

平均 (2) 对对 Q 中每个点 q_i , 计算其到 P 中最近点的距离, 并取平均。最终, 倒角距离为两者的和, 如公式 (3-18) 所示:

$$CD(P, Q) = \frac{1}{N} \sum_{p \in P} \min_{q \in Q} \|p - q\|_2 + \frac{1}{M} \sum_{q \in Q} \min_{p \in P} \|q - p\|_2 \quad (3-18)$$

关于点云的第二个评估指标为重建点云在指定距离阈值 τ 下的 F-Score。重建点云在阈值 τ 下的精确率 (Precision) 可以被定义为重建点云中有多少比例的点位置足够接近真实点云, 计算公式如公式 (3-19) 所示:

$$\text{Precision} = \frac{\sum_{p \in P} \mathbb{I} \left(\min_{q \in Q} \|p - q\|_2 \leq \tau \right)}{N} \quad (3-19)$$

式中: $\mathbb{I}(\cdot)$ ——指示函数, 当满足条件时, 值为 1, 否则值为 0。而召回率 (Recall) 可以被定义为真实点云中有多少比例的点被预测点云覆盖, 计算公式如公式 (3-20) 所示:

$$\text{Recall} = \frac{\sum_{q \in Q} \mathbb{I} \left(\min_{p \in P} \|q - p\|_2 \leq \tau \right)}{M} \quad (3-20)$$

最终 F-Score 可以被表示为公式 (3-21):

$$\text{F-Score} = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3-21)$$

3.6.4 实验设置

本文使用上文采集到的数据集对三维点云重建方法进行了全面的评估, 该数据集包括了大量的物体四个视角下的反射雷达信号数据, 以及作为标注的物体多视角深度图和采样得到的真实点云。本文按照 4:1:1 的比例将该数据集划分为训练集, 验证集和测试集, 划分过程中保证单个物体所属数据仅会出现在其中一个数据集中, 即网络模型在训练阶段并未见过验证集和测试集中物体的相关数据。

三维重建网络模型输出的深度图视角数被设置为 4, 深度图的分辨率设置为 128×128 , 预设深度值偏置被设置为 0.781, 与 Blender 进行深度图渲染时的相机深度保持一致。网络模型在单张 RTX 3090 显卡上进行训练, 网络模型使用的深度学习框架为 Pytorch 2.0.0, Python 版本为 3.8。网络模型训练过程中使用 Adam 优化器, 初始学习率设置为 1.0×10^{-4} , 并采取学习率分阶段衰减的策略, 网络模型一共训练 50 个 epoch, 在第 30 和第 40 个 epoch 时, 将学习率乘以衰减因子 0.3, 确保整个训练过程的稳定性; 权重衰减 (Weight Decay) 设置为 1.0×10^{-6} , 用于 L2 正则化, 防止模型过拟合; Adam 参数中的 β_1 和 β_2 分别为 0.9 和 0.999, 保持默认值; 训练过程中 BatchSize 设置为 8; 损

失函数中的两个权重 λ_{Mask} 和 λ_{Depth} 均设置为 1。

3.6.5 实验效果及评估

1) 总体性能评估

本文的三维点云重建方法在部分样本上的重建效果如图3-15所示，图中展示了真实点云和重建点云的对比，整体上达到了不错的重建效果。本文使用上文提到的三个评估指标在本文所采集的全部数据集上对本文的三维点云重建方法进行整体评估，实




图 3-15 三维点云重建效果

验结果如表3-1所示。

表 3-1 三维点云重建整体性能表现

类别	D-MAE (mm)	CD (cm)	F-Score (%)	
			τ	2τ
刀具	1.345	9.621	47.84	59.48
手机	0.590	4.222	62.68	76.28
扳手	2.193	10.23	44.35	56.73
易拉罐	0.881	1.689	85.24	99.84
显示器	5.661	6.139	56.79	67.77
水杯	0.628	1.944	80.74	98.01
笔记本电脑	3.206	3.908	58.50	81.75
键盘	0.972	4.859	61.24	70.89
平均值	1.934	5.326	62.17	76.34

表3-1中展示了本文所提出的三维点云重建方法在各个物体类别上的分别性能表

现, 以及最终的平均表现, 其中 D-MAE 指标用来评估网络模型预测的多视角深度图的精度, 单位为 mm, 越小越好; CD 指标作为最终合成预测点云与真实点云之间的距离度量, 单位为 cm, 越小越好; 同时, 表中展示了在一倍阈值 τ 和两倍阈值 2τ 下的 F-Score, 用于平均综合预测点云在一定容错下的精确率和召回率, 其中 τ 取 2cm, 后文中的 τ 均保持此值。从表中可以看出, 所有类别物体的平均 D-MAE 为 1.934mm, 平均 CD 为 5.326cm, τ 下的 F-Score 为 62.17%, 2τ 下的 F-Score 为 76.34%, 不同类别物体之间的性能表现存在一定差异, 性能表现较差的类别为刀具类和扳手类, 一方面由于这两类物体尺寸较小, 在采集雷达信号数据时物体的雷达反射截面 (Radar Cross Section, RCS) 较小, 致使采集到的雷达信号中关于物体三维结构的信息较少, 在遮挡情况下会进一步加剧该现象; 另一方面由于这两类物体类内形状差异较大, 训练集和验证集及测试集中数据分布差异较大, 导致网络模型性能在验证集和测试集上性能下降。而对于易拉罐和水杯两个类别, 由于三维形状结构简单加之类内数据分布一致, 本文三维点云重建方法在这两个类别上有着非常良好的性能表现。

2) 遮挡与非遮挡场景下性能评估

本文的基于脉冲超宽带雷达的三维点云重建方法相比于基于图像的方法, 最大的优势在于在物体可见性较差甚至被完全遮挡时仍然有比较好的性能表现, 为了验证这一观点, 本文在数据集采集过程中, 采集了部分物体被纸箱完全遮挡时的雷达信号数据, 将这部分数据按比例分布在训练集、验证集和测试集中, 并且对遮挡情况和非遮挡情况下的各类别物体三维点云重建性能表现进行了分别探究。遮挡情况和非遮挡情况下本文的三维点云重建方法在各类物体上的各个性能指标如图3-16所示。

遮挡和非遮挡情况下的 D-MAE 指标对比如图3-16(a)所示, 遮挡情况下的平均 D-MAE 为 2.224, 非遮挡情况下的平均 D-MAE 为 1.640, 主要差异体现在刀具和扳手两个类别上, 其他类别物体的 D-MAE 指标在遮挡和非遮挡情况下差异不大。CD 指标对比如图3-16(b)所示, 非遮挡下平均 CD 为 4.837, 遮挡下平均 CD 为 5.814, CD 误差仅上涨 0.997, 处于比较接近的水平, 差异较大的两个类别同样为刀具和扳手类。F-Score(τ) 对比如图3-16(c)所示, 遮挡下平均 F-Score(τ) 为 60.19%, 非遮挡下平均 F-Score(τ) 为 64.27%, 水平接近, 同样为刀具类和扳手类差异较大。F-Score(2τ) 对比如图3-16(d)所示, 遮挡下平均 F-Score(2τ) 为 74.79%, 非遮挡下平均 F-Score(2τ) 为 77.90%, 水平接近, 同样为刀具类和扳手类在遮挡情况下性能下降较多。刀具类和扳手类在遮挡情况下各个评估指标上的性能表现都有较大幅度的下降, 原因在于这两类物体在四个视角下的雷达反射截面较小, 致使雷达反射信号强度较小, 在被遮挡情况下, 这种现象会被进一步加剧, 信号强度的微弱导致信号中包含更少的物体三维结构信息, 致使三维点云重建性能大幅下降; 而对于其他拥有较大雷达反射截面的物体类别, 三维点云重建性能基本不受遮挡的影响。

综上所述, 在遮挡与非遮挡场景下三维点云重建方法的性能探究中发现, 本文所提出的方法仅在个别雷达反射截面较小的物体类别上, 会较大程度上被遮挡影响性能,




图 3-16 遮挡和非遮挡情况下各评估指标对比

对于绝大多数类别的物体，在遮挡情况下仍能保持较高的性能表现。

3) 单类别模型与通用模型的性能评估

本文探究了在单类别物体数据上训练的网络模型（单类别模型）在该类别物体上的性能表现与在整个数据集上训练的网络模型（通用模型）在该类别物体上的性能表现的差异。具体来说，本文将单个类别物体的对应数据从整体数据集中抽离出来构建为一个单类别的子数据集，同样按照比例划分为训练集、验证集和测试集，将网络模型在该子数据集上进行训练得到单类别模型，评估该单类别模型在该子数据集上的性能表现，并与在全部数据集上训练得到的通用模型的性能表现进行比较。

表 3-2 单类别模型和通用模型的性能表现

类别	CD (cm) ↓		F-Score(τ) (%) ↑		F-Score(2τ) (%) ↑	
	单类别	通用	单类别	通用	单类别	通用
刀具	8.129	9.621	58.34	47.84	62.60	59.48
手机	4.310	4.222	65.09	62.68	75.23	76.28
扳手	11.47	10.23	41.05	44.35	52.76	56.73
易拉罐	1.983	1.689	78.49	85.24	96.52	99.84
显示器	5.251	6.139	60.31	56.79	73.61	67.77
水杯	2.669	1.944	69.96	80.74	87.99	98.01
笔记本电脑	3.796	3.908	58.56	58.50	81.51	81.75
键盘	5.232	4.859	56.36	61.24	68.12	70.89
平均值	5.355	5.326	61.02	62.17	74.79	76.34

表3-2中展示了各类别物体上单类别模型和通用模型在各个评估指标上的表现。表中可以看出，对于大部分类别物体下的各项评估指标来说，通用模型都有与单类别模型接近甚至更好的性能表现，而对于整体平均值来说，单类别模型的 CD 为 5.355，通用模型的 CD 为 5.326；单类别模型的 F-Score(τ) 为 61.02%，通用模型为 62.17%；单类别模型的 F-Score(2τ) 为 74.79%，通用模型为 76.34%；对于三项指标，通用模型均具有较小程度上的领先。单类别模型是在数据分布更一致的子数据上进行训练的，而通用模型是在数据分布更复杂的整体数据集上进行训练的，上述数据表明通用模型并未在性能表现上产生下降，说明本文设计的网络模型具有足够的鲁棒性和泛化性；同时得益于通用模型从整体数据集上学习到的更通用的表征提取能力，反而使得通用模型在各类别物体上的性能表现得到一些提升。

4) 数据增强消融实验

在章节3.3中，本文提出了雷达信号数据的数据增强算法，该数据增强算法通过虚拟天线偏移（Virtual Antenna Shift, VAS）和相位旋转（Phase Rotation, PR）两种方式来生成物体的初始位置发生小范围位移时对应的雷达信号数据，对雷达信号数据的数据增强提升了数据集中的数据多样性，缓解了数据不足的问题，有效提升了模型的泛化能力，减少了模型过拟合的可能性。为了验证本文所提出的两种数据增强方式的有效性，本小节对两种数据增强方法进行了消融实验，一共有四种实验设置，第一种仅使用初始数据，并不进行任何数据增强，作为 Baseline；第二种仅使用虚拟天线偏移（VAS）方法对初始数据集进行数据增强；第三种仅使用相位旋转（PR）方法对初始数据集进行数据增强；最后一种同时使用两种方法对初始数据集进行数据增强（VAS+PR），这也是本文其他实验普遍使用的数据集；在这四种实验设置下的数据集上分别对模型进行训练和测试，探究不同实验设置下的模型性能表现。不同数据增强方式下各评估指标的整体表现如图3-17所示。

从图3-17中可以看出，对于全部四个评估指标，虚拟天线偏移（VAS）数据增强方




图 3-17 不同数据增强方式下各评估指标对比

法和相位旋转（PR）数据增强方法相比于不做任何数据增强的 Baseline 来说都有较为显著的性能提升，同时，结合两种方式的数据增强（VAS+PR）相比于单独一种数据增强方式又有较为明显的性能提升，在四个评估指标上均达到了最优性能，证明了本文提出的两种数据增强方式的有效性。

3.7 本章小结

本章提出了一种基于信号多视角逆投影融合的三维点云重建方法。该方法利用物体的运动为雷达产生大量的虚拟天线阵列，提升了超宽带雷达的感知能力；之后本文设计了针对超宽带雷达信号的背景反射消减方法和有效距离箱定位算法，来获取目标物体多视角下的去噪后的有效信号；针对数据集中雷达信号多样性缺失的问题，本文通过深入分析物体位置发生微小位移时的雷达信号变化，设计了虚拟天线偏移和相位旋转两种数据增强方法，提升了数据集的多样性；为了从物体多视角雷达信号中提取物体的三维结构信息，本文设计了一个三维重建神经网络，以多视角雷达信号作为输入，输出物体多视角下的深度图预测，随后通过深度图逆投影和点云融合获取物体最终的重建点云。

本章实验表明，本文的基于信号多视角逆投影融合的三维点云重建方法在重建精度上取得了优秀的性能表现，同时，即使在物体被完全遮挡的情况下，本文方法仍能保持较好的性能，针对数据增强方法的消融实验也表明本文提出的数据增强方法能有效

提升模型的性能表现。

4 基于信号域迁移的三维点云重建方法

4.1 引言

在上一章中,本文提出了一种基于信号多视角逆投影融合的三维点云重建方法,该方法通过为超宽带雷达构建出大量的虚拟天线来提升雷达感知能力,并通过背景反射消减和有效距离箱定位提取有效雷达信号,之后通过三维重建神经网络模型以及深度图逆投影和点云融合得到了物体最终的重建点云。然而三维重建神经网络模型依赖于大量的带多视角深度图标注的雷达信号训练数据,真实信号的采集流程复杂,多视角深度图标注困难,这导致了训练数据稀缺且多样性不足;同时,神经网络模型性能与训练数据所处数据域高度绑定,当将网络模型迁移到其他场景下的新的数据集上时,需要重新从头开始训练,这会消耗大量的时间以及算力成本。

针对上述问题,本章介绍本文的第二个贡献点,即提出了基于信号域迁移的三维点云重建方法,该方法以上章方法为基础,通过仿真信号与真实信号之间的域适应(Domain Adaptation)以及域迁移(Domain Transfer)提升了上章方法中三维重建网络模型在真实数据集上的数据效率,训练速度以及最终性能表现。本文首先设计了基于信号建模的雷达信号仿真算法,之后使用信号域适应神经网络模块对仿真信号进行域适应,减少信号在仿真域和真实域上的分布差异,通过仿真算法和信号域适应模块针对公开数据集中大量已有的物体三维模型生成对应的域适应后的仿真雷达信号,并与对应的物体三维结构标注数据构成规模庞大的仿真信号数据集;随后采用迁移学习中的“预训练-微调”两阶段学习范式对上一章中三维重建网络模型在仿真信号和真实信号之间进行域迁移。基于域迁移的训练方法相比于从头训练(Train from Scratch)的优势在于:(1)数据效率高,预训练模型已经从大规模数据中学习到了通用知识(雷达信号的特征,以及从特征到物体三维结构的映射关系),因此,只需要使用少量的真实数据在预训练模型上微调就能取得良好的性能表现。(2)训练成本低,相比于随机初始化的参数,预训练模型的参数已经接近于最优解,这大大减少了模型需要搜索的参数空间范围,因此只需要少量迭代即可让模型在真实数据集上收敛。(3)模型性能更好,由于对预训练模型高质量特征表示的直接继承,以及更稳定的训练优化过程,微调后的模型相比于从头训练的模型具有更好的性能表现。(4)更便捷的跨域迁移能力,得益于使用预训练模型在真实数据集上微调时极高的数据效率和极低的训练成本,使得模型可以快速迁移到其他场景下的数据域上。

4.2 基于信号建模的雷达信号仿真

本节探究如何通过基于信号建模的方法根据物体三维模型生成对应的初步仿真雷达信号。一些三维重建领域公开的数据集中包含了大量的物体三维模型,例如 ShapeNet

数据集^[30]，它是一个大规模、多类别的三维模型数据库，其中给出了每个三维模型高精度的多种三维表示，例如点云、三维网格等，本文通过基于信号建模的方式模拟超宽带信号经过三维模型反射后到达雷达接收端的接收信号，进而为大量三维模型生成对应的仿真雷达信号。

4.2.1 三维物体反射信号物理建模

在章节2.1.1中已经对雷达接收信号进行了详细的数学建模，具体见公式2-8，然而在该建模中，最终的接收信号被简单表示成多个路径反射信号的叠加，但并没有对每条路径的物理意义进行进一步讨论，如果要对三维物体的反射信号进行精确建模，必须考虑物体可能产生的每条反射路径。根据文献^[52,73]中对物体反射 WiFi 信号的建模方式，物体的整体反射信号可以被看做是物体三维网格（Mesh）的每个三角形面（Face）的反射信号的叠加，这种建模方式细化了物体作为反射物时产生的反射路径的粒度，本文参考该文献中的建模方式，对三维物体的超宽带雷达反射信号进行了物理模拟，如图4-1所示。




图 4-1 三维物体雷达信号模拟

本文对这种建模方式下的超宽带雷达接受信号进行了完整的数学推导。首先将反射路径细化为三维网格的每个三角形面，对雷达接收信号进行重写，如公式 (4-1) 所示：

$$y(t) = \sum_{f=1}^F A_f \cdot e^{j\theta_f} + n(t) \quad (4-1)$$

其中三角形面 f 对应的反射信号幅值为 $A_f = \frac{1}{2}\alpha_f g(t - kT_s - T_f)$ ，相位为 θ_f 为 $2\pi f_c T_f$ 。

在之前的讨论中，认为 α_p 是反射路径 p 的固有反射强度系数，这里， α_f 也可以认为是三角形面 f 的固有反射强度系数，为了准确估计每个三角形面的反射信号幅值，需要对 α_f 进行进一步的详细数学建模。对于每个三角形面的反射信号强度，会受到三个因素的影响：即三角形面与发射天线和接收天线的角度关系、三角形面与收发天线

的距离关系以及三角形面的面积大小。

首先考虑三角形面与收发天线角度对反射强度的影响。当三角形面和收发天线的位置关系如图4-2所示时，将发射天线和接收天线的位置坐标分别表示为 $l_t \in \mathbb{R}^3$ 和 $l_r \in \mathbb{R}^3$ ，该三角形面的三个顶点的坐标分别表示为 $v_a \in \mathbb{R}^3$ ， $v_b \in \mathbb{R}^3$ 和 $v_c \in \mathbb{R}^3$ ，那




图 4-2 三角形面与收发天线的位置关系

么该三角形面的中点坐标可以表示为 $l_f = \frac{v_a + v_b + v_c}{3}$, $l_f \in \mathbb{R}^3$ ，三角形面的单位法线向量可以通过向量 $\overrightarrow{v_a v_b}$ 和 $\overrightarrow{v_a v_c}$ 的叉乘计算得来，即：

$$\mathbf{n}_f = \frac{\overrightarrow{v_a v_b} \times \overrightarrow{v_a v_c}}{\|\overrightarrow{v_a v_b} \times \overrightarrow{v_a v_c}\|} \quad (4-2)$$

信号的入射向量可以近似为发射天线指向三角形面中点的向量 $\mathbf{I} = \frac{\overrightarrow{l_t l_f}}{\|\overrightarrow{l_t l_f}\|}$ ，如果三角形面是完美的镜面反射器（Specular Reflector）时，那么理想的出射向量如公式 (4-3) 所示：

$$\begin{aligned} \mathbf{R} &= \mathbf{I} - 2(\mathbf{I} \cdot \mathbf{n}_f)\mathbf{n}_f \\ &= \frac{\overrightarrow{l_t l_f}}{\|\overrightarrow{l_t l_f}\|} - 2 \frac{(\overrightarrow{l_t l_f}) \cdot \mathbf{n}_f}{\|\overrightarrow{l_t l_f}\|} \mathbf{n}_f \end{aligned} \quad (4-3)$$

然而在现实生活中，由于绝大多数物体都有着不同程度的粗糙表面，因此，每个三角形面并不适合被建模为镜面反射器，参考文献^[73]，本文将每个三角形面定义为准镜面反射器（Quasispecular Reflector），这是一种介于镜面反射器和漫反射器（Diffuse Reflector）之间的一种反射器，这种反射器的反射信号在理想出射向量方向上强度最高，同时也在其他方向上也会有有一定的反射强度，假如只考虑从三角形面到接收天线这个出射方向，

则对应的出射向量为 $\overrightarrow{l_f l_r} = l_r - l_f$ ，该出射向量和理想出射向量之间的夹角 γ 可以通过公式 (4-4) 计算得到：

$$\gamma = \arccos \left(\frac{\overrightarrow{l_f l_r} \cdot \mathbf{R}}{\|\overrightarrow{l_f l_r}\| \cdot \|\mathbf{R}\|} \right) \quad (4-4)$$

该出射方向上的反射强度 c_f 是一个与 γ 相关的变量：

$$c_f = e^{-\frac{\gamma^2}{2\sigma^2}} \quad (4-5)$$

式中： σ ——一个经验值； c_f ——可以当做是三角形面 f 的角度相关的反射强度系数。之后，考虑三角形面与收发天线的距离对反射强度的影响，参考文献^[52]，每个三角形面的反射强度应该与面到发射天线和面到接收天线的距离成反比，那么三角形面的距离相关的反射强度系数 d_f 为：

$$d_f = \frac{1}{\|\overrightarrow{l_f l_t}\| \cdot \|\overrightarrow{l_f l_r}\|} \quad (4-6)$$

最后考虑三角形面的面积大小对反射强度的影响，直观地，每个三角形面的反射强度应该与该三角形面的面积成正比，根据三角形面的面积计算公式，可以计算出三角形面 f 的与面积相关的反射强度系数 a_f ：

$$a_f = \frac{1}{2} \|\overrightarrow{v_a v_b} \times \overrightarrow{v_a v_c}\| \quad (4-7)$$

那么，最终，三角形面 f 的固有反射强度系数 α_f 可以表示为三个反射强度系数的乘积：

$$\begin{aligned} \alpha_f &= c_f \cdot d_f \cdot a_f \\ &= \frac{e^{-\frac{\gamma^2}{2\sigma^2}} \cdot \|\overrightarrow{v_a v_b} \times \overrightarrow{v_a v_c}\|}{2\|\overrightarrow{l_f l_t}\| \cdot \|\overrightarrow{l_f l_r}\|} \end{aligned} \quad (4-8)$$

三角形面 f 对应的反射信号的相位 θ_f 为 $2\pi f_c T_f$ ，此时， T_f 可以通过 f 到发射天线距离和 f 到接收天线距离的和除以光速计算出，即 $T_f = \frac{\|\overrightarrow{l_f l_t}\| + \|\overrightarrow{l_f l_r}\|}{c}$ ，则信号相位为：

$$\begin{aligned} \theta_f &= 2\pi f_c T_f \\ &= \frac{2\pi f_c (\|\overrightarrow{l_f l_t}\| + \|\overrightarrow{l_f l_r}\|)}{c} \end{aligned} \quad (4-9)$$

则最终，整个物体的反射信号可以被建模为公式 (4-10)：


$$\begin{aligned}
y(t) &= \sum_{f=1}^F A_f \cdot e^{j\theta_f} + n(t) \\
&= \sum_{f=1}^F \frac{1}{2} \alpha_f g(t - kT_s - T_f) \cdot e^{j2\pi f_c T_f} + n(t) \\
&= \sum_{f=1}^F \frac{e^{-\frac{\gamma^2}{2\sigma^2}} \cdot \|\vec{v_a v_b} \times \vec{v_a v_c}\| \cdot g\left(t - kT_s - \frac{\|\vec{l_f l_t}\| + \|\vec{l_f l_r}\|}{c}\right)}{4\|\vec{l_f l_t}\| \cdot \|\vec{l_f l_r}\|} \cdot e^{j\frac{2\pi f_c (\|\vec{l_f l_t}\| + \|\vec{l_f l_r}\|)}{c}} + n(t)
\end{aligned} \tag{4-10}$$

根据上式，当物体三维网格位置以及雷达发射天线和接收天线位置已知时，可以计算出每个三角形面对应的理论反射信号，并最终通过叠加每个三角形面的信号计算出整个物体的理论反射信号。


4.2.2 物体三维网格细分及遮挡面去除

在上一小节中，通过将物体的整体反射信号拆分成三维网格中每个小三角形面的反射信号的叠加，并对每个面的反射信号进行了详细的数学建模，最终计算出物体整体的反射信号。通过这种建模方式计算出的物体反射信号的精确程度很大程度上依赖于物体三维网格的细化程度，当三维网格中每个三角形面的面积足够小时，计算出的理论反射信号也更逼近于真实反射信号，因此，考虑在对物体反射信号仿真之前，先对物体三维网格进行细分（Subdivision）。

在 ShapeNet^[30]等公开数据集中，并不对物体三维网格中三角形面的精细程度做保证，尤其是当一些物体存在较平整的大面积区域时，这些平整区域可能仅由数个大的三角形面表示，这种粗略表示会影响物理模拟仿真信号的准确程度，本文设计了一种基于面积阈值的三维网格细分算法4-1，该算法能对三维网格中较大面积的面进行细分，确保最终的三维网格中所有三角形面都保持一个较高的精细程度。算法中首先为三角形面积设置一个阈值 A_{thresh} ，计算三维网格中每个三角形面积并挑选出面积大于阈值的面，对选中面执行细分操作，本文使用的细分方法为简单的线性细分，即通过连接原始三角形各边的中点，生成新的四个小三角形；通过不断迭代上述操作直到三维网格中所有面的面积都小于阈值。在真实应用时，考虑到不同物体的尺寸存在差异，为所有物体设置一个固定的面积阈值并不合理，因此考虑将面积阈值设置为固定阈值和动态阈值（三维网格面积和的 $1/n$ ）的较小值，即 $A_{\text{thresh}} = \min(0.02^2, \frac{\sum A}{n})$ ，确保所有三维物体都有一个相对精细的面积阈值。三维网格的细分效果如图4-3所示，图4-3(a)中为细分前的三维网格，可以看到存在许多面积巨大的三角形面，通过上述算法细分后的三维网格如图4-3(b)所示，较大三角形面被均匀细分为小三角形面。



(a) 细分前三维网格



(b) 细分后三维网格

图 4-3 三维网格细分前后对比

算法 4-1 三维网格细分算法**输入:**初始三维网格 $\mathcal{M}$, 包含点集 $V = \{v\}$ 和面集 $F = \{f\}$; 面积阈值 A_{thresh} **输出:** 细化后三维网格 $\mathcal{M}'$

```

1: function COMPUTEFACEAREAS( $V, F$ )
2:   for  $f_m \in F$  do
3:      $(i, j, k) \leftarrow f_m$  ▷ 三角形顶点
4:      $v_i \leftarrow V[i], v_j \leftarrow V[j], v_k \leftarrow V[k]$ 
5:      $\vec{e}_1 \leftarrow v_j - v_i, \vec{e}_2 \leftarrow v_k - v_i$ 
6:      $a \leftarrow 0.5 \times \|\vec{e}_1 \times \vec{e}_2\|$ 
7:      $A[m] \leftarrow a$ 
8:   end for
9:   return  $A$ 
10: end function

11: function SUBDIVISION( $\mathcal{M}, A_{\text{thresh}}$ )
12:    $A \leftarrow \text{ComputeFaceAreas}(V, F)$ 
13:    $\text{mask} \leftarrow [a > A_{\text{thresh}} \ \forall a \in A]$  ▷ 初始化细分掩码
14:   while  $\exists m \in \text{mask}$  where  $m = 1$  do ▷ 细分至所有三角形面面积小于阈值
15:      $\mathcal{M}' \leftarrow \text{Subdivide}(\mathcal{M}, \text{mask})$  ▷ 执行细分操作
16:      $A_{\text{new}} \leftarrow \text{ComputeFaceAreas}(V', F')$  ▷ 计算三角形面面积
17:      $\text{mask} \leftarrow [a > A_{\text{thresh}} \ \forall a \in A_{\text{new}}]$  ▷ 动态更新掩码
18:      $\mathcal{M} \leftarrow \mathcal{M}'$ 
19:   end while
20:    $\mathcal{M}' \leftarrow \mathcal{M}$ 
21:   return  $\mathcal{M}'$ 
22: end function

```

在通过叠加各三角形面的反射信号来得到物体最终的反射信号时，还需要考虑的问题是不同的三角形面之间存在遮挡，那些被其他面遮挡的面不应该产生反射信号，因此在进行反射信号仿真前，需要对被遮挡面进行去除。现存的遮挡面去除算法大多时间复杂度较高，例如光线投射（Ray Casting）法，时间复杂度为 $\mathcal{O}(m^2)$ ， m 为三维网格面的个数，深度缓冲（Z-Buffer）法，时间复杂度为 $\mathcal{O}(m \times k)$ ， k 为每个三角形的平均覆盖像素数，在后续的信号仿真中，由于每个虚拟天线的位置坐标都不一样，与物体的视线关系也会发生改变，因此对每个虚拟天线都需要执行一次遮挡面去除，上述时间复杂度较高的算法会带来巨大的计算成本。考虑到现实中物体大多为简单封闭物体，因此，对三维网格进行背面去除可以取得与遮挡面去除近似的效果，通过判断每个三角形面的法向量和视线向量的角度关系可以选取出三维网格相对于雷达位置的背面，计算时间复杂度为 $\mathcal{O}(m)$ ，本文通过这种方式来去除三维网格中的被遮挡面，具体见算法4-2。

算法 4-2 遮挡面去除算法

输入:

初始三维网格 $\mathcal{M}$ ，包含顶点集 $V = \{v\}$ 和面集 $F = \{f\}$
 发射天线位置 $\mathbf{l}_r \in \mathbb{R}^3$

输出: 遮挡面去除后的三维网格 $\mathcal{M}'$

```

1: function OCCLUSIONCULLING( $\mathcal{M}, \mathbf{l}_r$ )
2:    $F_{\text{visible}} \leftarrow \emptyset$                                 ▷ 初始化可见面集合
3:   for  $f \in F$  do                                       ▷ 遍历所有三角形面
4:      $\mathbf{c} \leftarrow \frac{1}{3}(\mathbf{v}_1 + \mathbf{v}_2 + \mathbf{v}_3)$ , 其中  $f = \{\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3\}$       ▷ 计算面中心点
5:      $\mathbf{V} \leftarrow \mathbf{c} - \mathbf{l}_r$                                 ▷ 生成视线向量
6:      $\mathbf{n} \leftarrow (\mathbf{v}_2 - \mathbf{v}_1) \times (\mathbf{v}_3 - \mathbf{v}_1)$               ▷ 法向量
7:      $\mathbf{n} \leftarrow \mathbf{n} / \|\mathbf{n}\|$ 
8:     if  $\mathbf{V} \cdot \mathbf{n}_j > 0$  then
9:        $F_{\text{visible}} \leftarrow F_{\text{visible}} \cup \{f\}$ 
10:    end if
11:  end for
12:   $\mathcal{M}' = (V, F_{\text{visible}})$ 
13:  return  $\mathcal{M}'$ 
14: end function

```

几何关系说明: 当视线向量 $\mathbf{V}$ 与法向量 $\mathbf{n}$ 的夹角 θ 满足:


$$\cos \theta = \frac{\mathbf{V} \cdot \mathbf{n}_j}{\|\mathbf{V}\| \|\mathbf{n}_j\|} > 0 \Rightarrow \theta < 90^\circ$$

时判定为可见面，否则执行遮挡面去除。


4.2.3 雷达信号仿真算法

在上一小节中，对物体三维网格进行了网格细分以及遮挡面去除，确保了最终的三维网格具有较精细的三角形面，同时仅保留了会产生反射信号的有效面，至此，可以从处理后的三维网格出发，根据章节4.2.1中对反射信号的建模方式，去生成对应的仿真信号。

根据章节3中对雷达信号数据的定义，一组信号数据可以表示为 $\mathbf{X} \in \mathbb{C}^{4 \times N \times M}$ ，对应4个视角下的虚拟天线 $\times$ 距离箱的复数信号矩阵，仿真信号数据 $\tilde{\mathbf{X}}$ 应该与 $\mathbf{X}$ 的维度尺寸保持一致。针对4个不同视角，可以通过设置不同的雷达坐标位置来模拟不同的雷达视角；不同的虚拟天线对应物体运动时与雷达不同的相对位置，因此可以通过为三维网格顶点坐标添加运动方向的偏移量来模拟物体的运动过程，已知物体运动时的初始位置偏移量 $\mathbf{O}_{start}$ 和结束位置偏移量 $\mathbf{O}_{end}$ ，那么就可以通过均匀采样的方法得到每个虚拟天线对应的物体位置偏移量；对于每个虚拟天线，已知雷达采样快时间间隔 $\mathbf{T}$ ，同样可以通过均匀采样得到每个距离箱对应的快时间采样点；雷达信号的采样过程可以参照章节4.2.1中的建模方式，计算每个三角形面的反射信号幅值与相位，最终将所有面的反射信号叠加得到整体的反射信号。现实中雷达的收发天线会被集成到非常接近的位置上，因此仿真的过程中可以近似认为发射天线和接收天线处于同一位置，即 $l_t = l_r = l$ 。完整的雷达信号仿真算法流程如算法4-3所示，该算法的时间复杂度为 $\mathcal{O}(N \times M \times K)$ ，其中 N 为虚拟天线数， M 为距离箱个数， K 为三维网格面个数，对于一个面数较多的三维网格，在CPU上执行该仿真算法的实际耗时可达数小时，本文通过GPU的多运算核心对算法进行并行加速，最终将算法的执行耗时降低到了分钟级别。为了验证仿真算法的正确性，本文将真实信号采集场景中的雷达相对位置及物体运动初始和结束位置偏移量带入到仿真算法中，生成了对应的仿真信号，并与真实信号做对比，图4-4为某个显示器单个视角下真实信号和仿真信号的幅值热图，从图中可以看出，仿真信号和真实信号在各个虚拟天线和距离箱上已经有着较高的相似度。



(a) 真实信号，横轴为虚拟天线，纵轴为距离箱



(b) 仿真信号，横轴为虚拟天线，纵轴为距离箱

图 4-4 同一个物体某视角下的真实信号和仿真信号幅值热图

算法 4-3 雷达信号仿真算法**输入:**

初始三维网格 $\mathcal{M}$, 包含顶点集 $V = \{v\}$ 和面集 $F = \{f\}$; 多视角下雷达位置数组 $\mathbf{L} \in \mathbb{R}^{4 \times 3}$; 物体运动初始位置偏移量 $\mathbf{O}_{start} \in \mathbb{R}^{4 \times 3}$, 结束位置偏移量 $\mathbf{O}_{end} \in \mathbb{R}^{4 \times 3}$; 雷达采样快时间间隔 $\mathbf{T}$

输出: 仿真信号 $\tilde{\mathbf{X}} \in \mathbb{C}^{4 \times N \times M}$

```

1:  $\mathcal{M} \leftarrow \text{Subdivision}(\mathcal{M}, A_{\text{thresh}})$  ▷ 视角  $\times$  虚拟天线  $\times$  距离箱
2: for  $i \leftarrow 1$  to 4 do ▷ 三维网格细分
3:    $\mathbf{l} \leftarrow \mathbf{L}[i]$  ▷ 视角  $i$  下雷达位置
4:    $\Delta \leftarrow (\mathbf{O}_{end}[i] - \mathbf{O}_{start}[i]) / (N - 1)$ 
5:    $\mathbf{O} \leftarrow \mathbf{O}_{start}[i] + [0, 1, \dots, N - 1]^T \cdot \Delta^T, \mathbf{O} \in \mathbb{R}^{N \times 3}$  ▷ 物体运动偏移矩阵
6:   for  $j \leftarrow 1$  to  $N$  do ▷  $N$  个虚拟天线
7:      $V' \leftarrow V + \mathbf{O}[j]$  ▷ 为每个顶点施加偏移
8:      $\mathcal{M}' \leftarrow (V', F)$ 
9:      $\mathcal{M}' \leftarrow \text{OcclusionCulling}(\mathcal{M}', \mathbf{l})$  ▷ 遮挡面去除
10:     $\mathbf{t} \leftarrow [0, 1, \dots, M - 1] \cdot \mathbf{T}, \mathbf{t} \in \mathbb{R}^M$  ▷ 均匀采样得到  $M$  个距离箱对应的采样点
11:    for  $k \leftarrow 1$  to  $M$  do ▷  $M$  个距离箱
12:       $\mathbf{S}_{sum} \leftarrow 0 + 0j$ 
13:      for  $f \in F$  do ▷ 计算每个面的反射信号并叠加
14:         $\{\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3\} \leftarrow f$ 
15:         $\mathbf{c} \leftarrow \frac{1}{3}(\mathbf{v}_1 + \mathbf{v}_2 + \mathbf{v}_3)$  ▷ 计算面中点
16:         $\mathbf{n} \leftarrow (\mathbf{v}_2 - \mathbf{v}_1) \times (\mathbf{v}_3 - \mathbf{v}_1)$  ▷ 法向量
17:         $\mathbf{a} \leftarrow \frac{1}{2} \|\mathbf{n}\|$  ▷ 计算面积
18:         $\mathbf{l} \leftarrow \frac{\mathbf{c} - \mathbf{l}}{\|\mathbf{c} - \mathbf{l}\|}$  ▷ 入射向量
19:         $\mathbf{R} \leftarrow \mathbf{l} - 2(\mathbf{l} \cdot \mathbf{n})\mathbf{n}$  ▷ 理想出射向量
20:         $\vec{cl} \leftarrow \frac{\mathbf{l} - \mathbf{c}}{\|\mathbf{l} - \mathbf{c}\|}$  ▷ 实际出射向量
21:         $\gamma \leftarrow \arccos\left(\frac{\vec{cl} \cdot \mathbf{R}}{\|\vec{cl}\| \cdot \|\mathbf{R}\|}\right)$  ▷ 与理想出射向量的夹角
22:         $\mathbf{T}_{of} \leftarrow \frac{2\|\mathbf{l}\|}{c}$  ▷ 信号飞行时间
23:         $\mathbf{A} \leftarrow \frac{\mathbf{a}}{\|\mathbf{l}\|^2} \cdot e^{-\frac{\gamma^2}{2\sigma^2}} \cdot g(\mathbf{t}[k] - \mathbf{T}_{of})$  ▷ 计算信号幅值
24:         $\theta \leftarrow 2\pi f_c \mathbf{T}_{of}$  ▷ 计算信号相位
25:         $\mathbf{S}_{sum} \leftarrow \mathbf{S}_{sum} + \mathbf{A} \cdot e^{j\theta}$  ▷ 叠加信号
26:      end for
27:       $\tilde{\mathbf{X}}[i, j, k] \leftarrow \mathbf{S}_{sum}$ 
28:    end for
29:  end for
30: end for

```

4.3 信号域适应网络模块

在上一节中，通过对三维物体反射信号进行详细建模，将三维物体的整体反射信号拆分成每个三角形面反射信号的线性叠加，并在之后对物体三维网格进行细分及遮挡面去除，提升了三维网格的精细程度，并保留了有效反射面，最终实现了物体反射雷达信号仿真。仿真出的信号与真实信号已经具有较高的相似度了，但由于理论建模与真实世界的固有差异，加之真实信号采集时引入的各种干扰及噪声，导致仿真信号和真实信号仍存在一定差异，即信号在仿真域和真实域之间仍存在一定的分布差异，因此，本节设计了一个信号域适应网络模块，通过该网络模型进一步较少信号在仿真域和真实域上的分布差异。

4.3.1 神经网络模型

首先考虑网络模型的输入和输出，信号域适应网络模块的目的是较少信号在仿真域和真实域上的分布差异，因此输入应为通过雷达信号仿真算法得到的初步仿真信号 $\tilde{\mathbf{X}}$ ，输出则为域适应之后的仿真信号 $\hat{\mathbf{X}}$ ，网络优化的目标是使得 $\hat{\mathbf{X}}$ 接近于对应的真实信号 $\mathbf{X}$ ，对于单个视角来说， $\tilde{\mathbf{X}} \in \mathbb{C}^{N \times M}$ ，初步仿真信号是一个复数矩阵，可以将其拆分成幅值和相位，本文在前期实验探究中发现，将初步仿真信号的幅值和相位同时输入网络，让网络输出域适应后的幅值和相位，这种输入输出设置下的网络模型在训练过程中极不稳定，难以收敛，这种现象也很容易去解释：（1）信号相位数据固有的周期性和边界敏感性（在 0 和 2π 之间跳变），导致该数据对应的特征空间分布复杂，难以被网络模型学习。（2）在章节3.3中，理论推导和验证实验都表明了，对于同一个物体，当物体与雷达之间距离发生微小的位移，都会引起信号相位的巨变，这进一步加大了相位数据对应特征空间的复杂程度。因此，本文仅对仿真信号的幅值进行域适应，仿真信号的域适应过程如图4-5所示，首先获取仿真信号的对应幅值 $\tilde{\mathbf{A}} = |\tilde{\mathbf{X}}|$, $\tilde{\mathbf{A}} \in \mathbb{R}^{N \times M}$ 以及对应的相位 $\tilde{\Phi} = \angle \tilde{\mathbf{X}}$, $\tilde{\Phi} \in \mathbb{R}^{N \times M}$ ，将相位 $\tilde{\Phi} = \angle \tilde{\mathbf{X}}$ 保留，并将幅值 $\tilde{\mathbf{A}} = |\tilde{\mathbf{X}}|$ 输入到信号域适应网络模块中，得到域适应后的信号幅值 $\hat{\mathbf{A}}$ ，网络训练过程中将 $\hat{\mathbf{A}}$ 与真实信号幅值 $\mathbf{A} = |\mathbf{X}|$ 做损失来对网络模型进行优化，最后将 $\hat{\mathbf{A}}$ 与之前保留的相位数据 $\tilde{\Phi}$ 组合成完整的域适应后信号 $\hat{\mathbf{X}} = \hat{\mathbf{A}} \odot e^{j\tilde{\Phi}}$, $\hat{\mathbf{X}} \in \mathbb{R}^{N \times M}$ 。

由于物理模拟产生的初步仿真信号与真实信号已经有足够的分布相似度，因此，信号域适应的任务相对较为简单，本文设计的信号域适应网络模块也是一个结构较为简单的轻量型的编码器-解码器架构神经网络模型。对于编码器的设计，考虑到输入的仿真信号幅值 $\tilde{\mathbf{A}} \in \mathbb{R}^{N \times M}$ 尺寸为 2800×9 ，对应虚拟天线数和距离箱数，与章节3.4中的三维重建神经网络的输入类似，都适合被看做是多通道的一维序列，因此，对应的编码器同样也是基于一维卷积，具体的网络结构见图4-6。编码器由五层卷积块（ConvBlock）级联构成，每个卷积块由一维卷积层（Conv1D）、一维批归一化层（BatchNorm）和带泄露修正线性单元（LeakyReLU）组成，一维卷积层负责对一维序列完成局部特征提取；批归一化层负责对通道维度进行标准化操作，抑制内部协变量偏移（Internal Covariate




图 4-5 信号域适应网络模块

Shift) 现象, 提升训练稳定性; LeakyReLU 作为激活函数, 相比与普通 ReLU, LeakyReLU 引入非线性变换, 在保留负值信息的同时缓解神经元失活问题。整个卷积块的数学描述为:

$$\begin{aligned} \mathbf{F}_{\text{out}} &= \text{ConvBlock}(\mathbf{F}_{\text{in}}) \\ &= \text{LeakyReLU}(\text{BatchNorm}(\text{Conv1D}(\mathbf{F}_{\text{in}}))) \end{aligned} \quad (4-11)$$

编码器通过将五层卷积块堆叠起来去逐级提取输入的仿真信号幅值的各种层次的特征, 前三层卷积块使用较大的卷积核大小 (15 $\rightarrow$ 11 $\rightarrow$ 7) 来获取更大的感受野, 同时设置




图 4-6 信号域适应网络编码器

步长为 2 来对特征图逐步下采样，特征图的长度逐步缩小 ($2800 \rightarrow 1400 \rightarrow 700 \rightarrow 350$)；后两层卷积块则使用较小的卷积核大小 ($5 \rightarrow 3$) 来提取更精细的特征，同时为了避免对特征图过度压缩导致信息丢失，后两层卷积设置步长为 1，保持特征图的长度为 350 不变；五层卷积块输出的特征图的通道数逐步扩展 ($9 \rightarrow 64 \rightarrow 128 \rightarrow 256 \rightarrow 512 \rightarrow 1024$)，因此编码器最终得到的特征 $\mathbf{F} \in \mathbb{R}^{350 \times 1024}$ ，即长度为 350，通道数为 1024。

本文设计的解码器由五层逆卷积块 (DeconvBlock) 级联构成，与编码器形成对称拓扑结构，如图4-7，旨在将高维特征 (输入尺寸: 350×1024) 逐步重建为原始信号空间 (输出尺寸: 2800×9)，最终输出域适应后的信号幅值。逆卷积块的结构域卷积块的结构类似，由一维转置卷积层 (ConvTranspose1D)、BatchNorm 和 LeakyReLU 组成，逆卷积块的数学描述为：

$$\begin{aligned} \mathbf{F}_{\text{out}} &= \text{DeconvBlock}(\mathbf{F}_{\text{in}}) \\ &= \text{LeakyReLU}(\text{BatchNorm}(\text{ConvTranspose1D}(\mathbf{F}_{\text{in}}))) \end{aligned} \quad (4-12)$$

与编码器中后两层卷积块相对称，解码器的前两层逆卷积块中转置卷积的步长设置为 1，使得特征图长度保持不变，同时使用较小转置卷积核 ($3 \rightarrow 5$)，聚焦局部细节重建；后三层逆卷积块中转置卷积的步长设置为 2，进行三级上采样，特征图的长度逐步增长 ($350 \rightarrow 700 \rightarrow 1400 \rightarrow 2800$)，同时使用的转置卷积核也逐步增大 ($7 \rightarrow 11 \rightarrow 15$)；五层逆卷积块输出的特征图的通道数逐步减少 ($1024 \rightarrow 512 \rightarrow 256 \rightarrow 128 \rightarrow 64 \rightarrow 9$)，最终输出域适应后的信号幅值 $\hat{\mathbf{A}} \in \mathbb{R}^{2800 \times 9}$ ；需要注意的是，为了保证最终输出的信号幅值的动态范围，在最后一层逆卷积块中省略了批归一化层和激活函数，直接输出原始的卷积值。




图 4-7 信号域适应网络解码器

4.3.2 损失函数设计

本小节为上文介绍的信号域适应网络模块设计合理的损失函数，为模型的训练提供合理的优化约束条件。模型的输出是域适应后的仿真信号幅值 $\hat{\mathbf{A}} \in \mathbb{R}^{N \times M}$ ，网络优化的目标应该是使得 $\hat{\mathbf{A}}$ 尽可能接近真实信号的幅值 $\mathbf{A}$ ，作为一个典型的回归任务，最直观的思想是直接使用均方误差（Mean Squared Error, MSE）等回归任务常用的损失函数，然而，真实信号幅值在不同通道上的能量分布并不均衡，呈现出中间通道上能量较高，两侧通道上能量较低的现象，如果使用普通的 MSE 损失函数，那么模型的优化方向会被高能量通道所主导，导致低能量通道的回归效果变差。

因此，本文设计了一种通道自适应加权均方误差（Channel Adaptive Weighted MSE, CAW-MSE）损失函数，根据每个通道的能量强度来为每个通道生成对应的权重，具体而言，每个通道的权重可以用公式 (4-13) 计算：

$$w_m = \frac{1}{\sqrt{\sum_{b=1}^B \sum_{n=1}^N |\mathbf{A}_{b,n,m}| + \epsilon}}, \quad m = 1, 2, \dots, M \quad (4-13)$$

式中： $\mathbf{A}$ ——真实信号幅值； B ——批次大小； M ——通道数； N ——虚拟天线数； $\epsilon = 10^{-10}$ ——数值稳定项，避免除零。通过这种方法为能量较高的通道赋予较小的权重，为能量较低的通道赋予较大的权重，整体的损失函数如公式 (4-14)：

$$\mathcal{L}_{\text{CAW-MSE}} = \sum_{m=1}^M w_m \cdot \frac{1}{BN} \sum_{b=1}^B \sum_{n=1}^N \left(\mathbf{A}_{b,n,m} - \hat{\mathbf{A}}_{b,n,m} \right)^2 \quad (4-14)$$

4.4 仿真信号域迁移

前两节中介绍了基于信号建模的雷达信号仿真以及基于深度学习的仿真信号域适应，通过这两个步骤，可以从物体三维模型得到域适应后的仿真信号数据，基于此，本文可以通过公开数据集中大量的物体三维模型生成对应的仿真信号并构建出一个大规模的仿真信号数据集，之后，采用迁移学习中的“预训练（Pre-training）-微调（Fine-tuning）”两阶段学习范式，首先将章节3.4中的三维重建网络模型在仿真信号数据集上进行预训练，得到已经学习到通用知识的预训练模型，之后仅在真实信号数据集上进行简单微调，即可达到良好的性能表现。

4.4.1 仿真信号数据集

根据章节3中对真实信号数据集的定义，真实信号数据集中包含了物体四个视角下的真实雷达信号数据以及作为标注的固定视角下的深度图，仿真信号数据集应该与真实信号数据集相对应，包含物体四个视角下的仿真信号数据以及作为标注的深度图。

仿真信号数据集的生成流程如图4-8所示，首先从 ShapeNet^[30]中挑选出大量的三维

物体实例，这些三维物体分属于不同的类别之下，ShapeNet 中包含了这些三维物体的三维网格文件（.obj 文件），将物体的三维网格、多视角下雷达位置、物体运动偏移量和雷达采样间隔等参数输入到算法4-3中，算法通过基于信号建模的方法得到物体四个视角下的初步仿真信号。




图 4-8 仿真信号数据集生成流程

之后使用章节4.3中的信号域适应网络模块对初步仿真信号进行域适应，减少信号在仿真域和真实域上的分布差异。针对信号域适应网络模块，本文专门构建了一个较小规模的由真实信号和初步仿真信号组成的信号域适应数据集用于信号域适应网络的训练，具体而言，在章节3.6.2中，本文已经采集了大量的 3D 打印的真实物体的真实雷达信号，同时也拥有这些物体对应的三维网格，因此可以使用物理模拟的方法生成对应的初步仿真信号，这两部分信号中的对应样本两两构成一个样本对，构建起了一个用于训练信号域适应网络的数据集，将信号域适应网络在该数据集上进行充分的训练并保留对应的模型权重。最后使用训练好的信号域适应网络对 ShapeNet 中物体的初步仿真信号进行域适应，得到最终的仿真信号。

除了为 ShapeNet 中的物体生成仿真信号，还需要为物体生成对应的多视角下的深度图，作为三维重建网络模型在仿真数据集上训练时的 Ground Truth。与章节3.6.2中为真实数据集中物体生成深度图的方法保持一致，本文使用开源三维建模工具 Blender（版本 2.78）来对物体进行深度图渲染，具体而言，通过 Blender 提供的 Python API 编写脚本实现了自动化的渲染过程，首先导入目标物体的三维网格（.obj 格式），之后设置相机位置坐标以及旋转矩阵，相机类型选择正交相机（Orthographic Camera），因此无需设置焦距等内参，只需设置缩放因子，最后进行深度图渲染，得到分辨率为 128×128 的深度图，为了获取多个视角下的深度图，对物体三维网格进行固定方位角的旋转，进

行多次渲染。

通过上述流程获取到了 ShapeNet 中物体对应的仿真信号，以及作为标注的多视角下的深度图，两两构成一个样本对，为了进一步扩展仿真数据集的规模，对仿真数据集中的仿真信号同样使用章节3.3中的数据增强方法，扩展数据集中的样本个数，最终构建出了一个规模巨大的仿真信号数据集。

4.4.2 基于迁移学习的两阶段训练

本文希望使用迁移学习的方法将第三章中的三维重建神经网络模型在仿真信号数据集上学习到的通用知识迁移到真实信号数据集上，提升模型在真实信号数据集上的性能表现，同时减少模型在真实信号数据集上的训练成本，因此，本文采取了迁移学习中的“预训练-微调”两阶段学习范式来对模型进行训练，具体训练流程见图4-9。根




图 4-9 两阶段训练过程

据迁移学习领域中对域的定义，仿真信号数据集应该被定义为源域，数学表示为：

$$D_s = \{(x_i^s, y_i^s)\}_{i=1}^{N_s} \quad (4-15)$$

式中： x_i^s ——仿真信号数据集中第 i 个样本的仿真信号； y_i^s ——第 i 个样本的标注，即物体多视角下的深度图； N_s ——仿真信号数据集的样本数量。真实信号数据集则应该被定义为目标域，数学表示为：

$$D_t = \{(x_j^t, y_j^t)\}_{j=1}^{N_t} \quad (4-16)$$

式中： x_j^t ——真实信号数据集中第 j 个样本的仿真信号； y_j^t ——第 j 个样本的标注，即物体多视角下的深度图； N_t ——真实信号数据集的样本数量。

为了从仿真信号数据集中学习到充分的通用知识，本文先将三维重建神经网络模

型在仿真信号数据集上进行充分的预训练，对模型参数进行优化：

$$\theta_{\text{pretrain}} = \arg \min_{\theta} \mathcal{L}_{\text{pretrain}}(\theta; D_s) \quad (4-17)$$

通过学习，得到了在仿真信号数据集上表现良好的模型参数 θ_{pretrain} ，由于仿真信号数据集经过信号域适应网络模块处理，在数据分布上和真实信号数据集已经非常相似，因此，模型在仿真信号数据集上学习到的知识在真实信号数据集上很大程度上也会适用，所以，将在仿真信号数据集上预训练好的模型参数 θ_{pretrain} 迁移到真实信号数据集上进行简单的微调，就会得到良好的性能表现，数学表示如下：

$$\theta_{\text{finetune}} = \arg \min_{\theta} \mathcal{L}_{\text{finetune}}(\theta; D_t), \quad \text{s.t. } \theta_{\text{init}} = \theta_{\text{pretrain}} \quad (4-18)$$

将预训练模型的模型参数 θ_{pretrain} 作为微调阶段的初始模型参数，并在真实信号数据集上进行微调训练，得到最终的模型参数 θ_{finetune} 。得益于预训练模型已经从源域仿真信号数据集中学习到了大量的通用知识，其中包括雷达信号低层次特征提取能力以及高层次特征到空间几何的映射能力等，将预训练模型迁移到真实信号数据集上进行微调，相比于在真实信号数据集上从头训练，可以大大降低模型训练的迭代次数以及训练所需的数据量，同时也会在一定程度上提升模型在真实信号数据集上的性能表现。

4.5 实验及结果分析

本章的实验主要分为两个部分，第一部分针对本文的信号仿真算法及信号域适应网络模块进行实验评估，第二部分针对三维重建神经网络模型从仿真信号数据集到真实信号数据集的域迁移进行实验评估。

4.5.1 域适应实验评估

1) 数据集准备

在章节3.6.2中，本文已经采集了大量 3D 打印的真实物体的真实雷达信号，同时拥有这些物体的真实三维网格，因此，可以使用信号仿真算法生成这些三维网格对应的初步仿真信号，通过计算初步仿真信号相较于真实信号的精度表现来评估信号仿真算法的性能表现。同时为了训练和评估信号域适应网络模块，本文将初步仿真信号与对应的真实信号构成样本对，其中初步仿真信号作为网络的输入，真实信号作为网络输出的域适应后仿真信号对应的 Ground Truth，构建成了一个信号域适应数据集。

为了扩展数据集中的数据多样性，本文采用类似算法3-2的做法对数据集进行数据增强，但由于信号域适应网络只对信号的幅值进行域适应，因此，这里仅使用虚拟天线偏移（Virtual Antenna Shift, VAS）的数据增强方式，而不进行相位旋转（Phase Rotation, PR）。最终，数据集中包含 16,800 条真实雷达信号数据，以及同样数量的初步仿真信号数据，并按照 75%，25% 的比例划分为训练集和测试集。

2) 评估指标

为了评估初步仿真信号和域适应后仿真信号的精度（仅针对信号幅值），本文采取了以下三种评估指标，分别为余弦相似度（Cosine Similarity），平均绝对误差（Mean Absolute Error, MAE），均方误差（Mean Squared Error, MSE）。

假设仿真信号为 $\mathbf{A} \in \mathbb{R}^{M \times N}$ ，真实信号为 $\mathbf{B} \in \mathbb{R}^{M \times N}$ ，其中 M 为虚拟天线数， N 为距离箱个数。余弦相似度定义如下：

$$\text{Cosine} = \frac{1}{N} \sum_{j=1}^N \frac{\sum_{i=1}^M A_{i,j} B_{i,j}}{\sqrt{\sum_{i=1}^M A_{i,j}^2} \sqrt{\sum_{i=1}^M B_{i,j}^2}}, \quad (4-19)$$

式中： $A_{i,j}$ ， $B_{i,j}$ ——仿真信号和真实信号第 i 个虚拟天线的第 j 个距离箱的信号幅值。通过计算每个距离箱下信号的余弦相似度，最后对所有距离箱取平均，值域为 $[-1, 1]$ ，值越接近 1 表示仿真信号各距离箱之间的信号幅值与真实信号趋势更一致。

MAE 定义如下：

$$\text{MAE} = \frac{1}{N} \sum_{j=1}^N \left(\frac{1}{M} \sum_{i=1}^M |A_{i,j} - B_{i,j}| \right), \quad (4-20)$$

为了消除信号幅值量纲的影响，在计算 MAE 之前对仿真信号和真实信号都归一化到 $[0, 1]$ 之间，因此，MAE 的值域也为 $[0, 1]$ ，值越小表示精度越高，MAE 直接反映信号间整体误差的绝对大小。

MSE 定义如下：

$$\text{MSE} = \frac{1}{N} \sum_{j=1}^N \left(\frac{1}{M} \sum_{i=1}^M (A_{i,j} - B_{i,j})^2 \right), \quad (4-21)$$

计算 MSE 之前，同样对信号做归一化，因此 MSE 值域也为 $[0, 1]$ ，值越小表示精度越高，相比 MAE，MAE 对大幅值误差更敏感。

3) 实验评估

将信号域适应网络在上述数据集上进行充分训练，一共训练 130 个 epoch，同样采取学习率分阶段衰减的策略，在第 30、第 70、第 90 和第 110 个 epoch 时，将学习率乘以衰减因子 0.3，初始学习率设置为 1.0×10^{-4} ，其余优化器参数设置与 3 中保持一致。

之后在测试集上对信号域适应网络的性能进行评估，即对域适应后的仿真信号精度进行评估，并且与初步仿真信号的精度进行比较，实验结果如表 4-1 所示。

表 4-1 初步仿真信号与域适应后仿真信号精度对比

仿真阶段	余弦相似度 ↑	MAE ↓	MSE ↓
初步仿真信号	0.8411	0.2540	0.1053
域适应后仿真信号	0.9363	0.1674	0.0501

表4-1中展示了初步仿真信号与域适应后仿真信号的精度在三个评估指标下的对比,对于信号仿真算法产生的初步仿真信号来说,相比于真实信号,余弦相似度为0.8411,说明初步仿真信号与真实信号已经具有较高的相似度,MAE和MSE也都处于一个较低的水平,说明整体误差较小,验证了本文提出的基于信号建模的信号仿真算法的有效性。同时,相比于初步仿真信号,信号域适应网络产生的域适应后的仿真信号,在三个评估指标下,均取得了一定程度的精度提升,说明本文设计的信号域适应网络模块有效缩小了信号在仿真域与真实域上的分布差异,让最终的仿真信号拥有足够高的精度表现。

4.5.2 域迁移实验评估

为了验证本文从仿真信号数据集到真实信号数据集的迁移学习方法的有效性,本文对这种训练方法下的网络模型的性能表现、训练速度以及数据效率等各方面结果与从头训练方法下的结果做了全面的对比实验评估。

1) 数据集准备

该部分实验涉及到两个数据集,一个是作为迁移学习中的源域的仿真信号数据集,另一个是作为迁移学习中的目标域的真实信号数据集。

对于仿真信号数据集,参照章节4.4.1中的仿真信号数据集生成方法,本文从ShapeNet数据集中挑选了属于13个类别的共390个物体,首先使用雷达信号仿真算法4-3生成每个物体四个视角下的初步仿真信号,之后使用训练好的信号域适应网络对初步仿真信号进行域适应,得到域适应后的仿真信号;为了进一步扩展仿真信号数据集的规模,本文使用数据增强算法3-2对域适应后的仿真信号进行数据增强,最终仿真信号数据集中共包含156,000条雷达信号数据,并80%和20%的比例划分为训练集和测试集。

为了获取ShapeNet中物体的多视角深度图,参照章节3中的方式,同样使用Blender(版本2.78)来对ShapeNet中物体的三维网格进行深度图渲染,同时,对物体三维网格进行平均取样,得到致密真实点云数据。

对于真实信号数据集,沿用章节3.6.2中的数据集。

2) 实验设置

对于网络模型训练的基础实验设置,与章节3.6.4中保持一致。针对在仿真信号数据集上的预训练阶段,为了让模型在源域上学习到足够的通用知识,将模型在仿真信号数据集的训练集上共训练110个epoch,同样采取学习率分阶段衰竭的策略,在第30、第70和第90个epoch时,将学习率乘以衰减因子0.3,初始学习率为 1.0×10^{-4} ,同样使用Adam优化器,参数配置与前文保持一致。针对在真实信号数据集上的微调阶段,为了与章节3中的在真实信号数据集上从头训练作对比,因此,微调阶段的训练设置与从头训练时的训练设置保持一致。

3) 仿真信号数据集上三维点云重建性能评估

为了验证预训练阶段三维重建网络模型在仿真信号数据集是否进行了充分学习,本文对三维重建网络模型在仿真信号数据集上的性能表现进行了完整评估,评估指标沿

用章节3.6.3中的评估指标。仿真信号数据集上三维点云重建方法的性能表现如表4-2所示。

表 4-2 仿真信号数据集上三维点云重建性能表现

类别	D-MAE (mm)	CD (cm)	F-Score (%)	
			τ	2τ
飞机	0.994	4.325	66.42	80.47
长凳	2.089	6.357	52.94	67.22
橱柜	1.767	6.135	54.12	69.45
汽车	1.375	6.156	44.16	64.12
椅子	1.870	4.354	60.60	79.51
显示器	1.216	6.090	59.52	71.11
灯	1.025	7.380	47.80	64.44
扬声器	1.901	5.661	57.56	73.30
步枪	0.550	6.311	61.52	71.26
沙发	1.610	6.118	50.70	68.04
桌子	1.056	5.581	55.00	69.06
电话	0.773	6.253	59.15	68.46
船只	1.420	5.502	61.45	75.88
平均值	1.357	5.863	56.23	70.95

表4-2中展示了三维点云重建方法在仿真信号数据集中各类别物体的性能表现，以及最终的平均表现，各项评估指标与章节3中该方法在真实信号数据集中的表现接近，均保持在较高的水平，说明了三维重建神经网络模型在仿真信号数据集上进行了充分的训练，并学习到了仿真信号数据中的特征分布，以及到物体三维结构的映射关系，同时，也侧面印证了本文的信号仿真算法以及信号域适应网络模块的合理性。

4) 基于信号域迁移的三维点云重建方法性能实验评估

将在仿真信号数据集上进行充分预训练的模型权重迁移到真实信号数据集上进行微调，由于预训练模型已经在仿真信号数据集上学习到了大量的通用知识，例如高质量的特征表示能力等，并且微调相比于从头训练会有更稳定的训练优化过程，因此，微调后的网络模型相较于从头训练的模型会有更好的性能表现，为了验证这一观点，本文对从头训练与微调的模型分别的性能表现进行了实验探究，实验结果如表4-3所示。表4-3中展示了从头训练的模型以及微调模型的分别性能表现，从表中可以看出，整体上，微调模型相比于从头训练模型取得了更好的性能，微调模型的重建点云的 CD 误差降低至 4.868cm，相较于从头训练模型降低了 0.458cm，取得了更高的精度，微调模型的 F-Score(τ) 相较于从头训练模型提高了 4.44%，F-Score(τ) 则提高了 2%。分析各类别物体上的分别性能表现，微调模型相较于从头训练模型，不容易过分关注于个别类别物体，而更关注于整体数据集，因此在一些从头训练模型表现较差的物体类别上，微调

表 4-3 真实信号数据集上从头训练模型与微调模型性能表现

类别	CD (cm) ↓		F-Score(τ) (%) ↑		F-Score(2τ) (%) ↑	
	从头训练	微调	从头训练	微调	从头训练	微调
刀具	9.621	6.815	47.84	62.41	59.48	67.58
手机	4.222	4.077	62.68	66.86	76.28	84.70
扳手	10.23	10.28	44.35	53.29	56.73	58.75
易拉罐	1.689	2.385	85.24	82.72	99.84	93.71
显示器	6.139	4.684	56.79	65.12	67.77	75.30
水杯	1.944	2.545	80.74	72.26	98.01	89.56
笔记本电脑	3.908	3.439	58.50	67.06	81.75	84.22
键盘	4.859	4.717	61.24	63.13	70.89	72.91
平均值	5.326	4.868	62.17	66.61	76.34	78.34

模型会有较大的提升,例如刀具、显示器等,不过在一些从头训练模型表现异常好的物体类别上,微调模型可能会有一定程度的性能下降,例如易拉罐、水杯等。综上所述,预训练-微调的训练策略通过迁移通用特征表示与稳定优化过程使微调模型整体性能显著提升,并且其正则化效应缓解了类别过拟合问题。

5) 基于信号域迁移的三维点云重建方法数据效率实验评估

对于基于深度学习的三维重建点云方法,数据采集的高成本与标注复杂性使得模型的数据效率成为一个关键指标。得益于本文的信号仿真算法和信号域适应网络模块,作为源域的仿真信号数据集与作为目标域的真实信号数据集在数据分布上具有足够的相似性,因此在源域上充分训练的预训练模型在真实信号数据集上进行微调时会具有更高的数据效率,即用更少的训练数据便能达到一样的性能表现。本文通过逐步减少三维重建网络模型在真实信号数据集上所用训练数据数量(训练数据占总训练集的比例),来探究从头学习模型和微调模型在不同数量训练数据下的性能表现,进而比较两者的数据效率。实验结果如图4-10所示。

图4-10中展示了使用不同数量训练数据下微调模型和从头学习模型在各评估指标上的分别表现。从图中可以看出,当使用训练数据超过总训练集的30%以上时,微调模型和从头训练模型均保持在一个比较接近的较高水平,然而,当使用训练数据低于总训练集的30%时,从头训练模型的性能会出现灾难性的下降,当使用总训练集5%的数据进行训练时,从头训练模型的D-MAE误差提升至10.67mm,CD误差提升至11.92cm,F-Score(τ)和F-Score(2τ)分别下降至50.89%和69.15%,远低于使用全部训练集中数据进行训练时的模型性能。而对于微调模型来说,即使仅使用5%的数据来训练,模型性能在四个评估指标上的表现仍没有明显下降,重建点云的CD误差为5.175cm,相较于全量数据训练时仅上升0.307cm,充分说明了预训练-微调的迁移学习相较于从头训练在真实信号数据集上有着更高的数据效率。




图 4-10 真实信号数据集上微调模型和从头训练模型数据效率对比

6) 基于信号域迁移的三维点云重建方法训练速度实验评估

当将基于深度学习的三维点云重建方法在不同的场景之间进行迁移时，如果不同场景下数据分布差异过大，例如物体类别差异过大、多径环境差异过大等，需要将神经网络模型在新数据集上进行重新训练，此时，模型的训练速度成为迁移便捷与否的一个关键因素。本文对从头训练模型和基于域迁移方法的微调模型在真实信号数据集上的训练速度分别进行了实验评估，实验结果如图4-11所示。




图 4-11 真实信号数据集上微调模型和从头训练模型训练速度对比

本文从两方面去考虑模型训练速度的评估，一方面是训练过程中 loss 的下降速度，一方面是训练过程中模型在验证集上性能提升速度。图4-11(a)中展示了微调模型和从

头学习模型在训练过程中的 loss 下降曲线，从图中可以看出，微调模型在大约 7000 个 step 处（大约第 8 个 epoch）就接近收敛，而从头训练模型在大约 35000 个 step 处（大约第 44 个 epoch）才逐渐收敛。图4-11(b)中展示了微调模型和从头学习模型在训练过程中在验证集上的 D-MAE 变化曲线，图中可以看到，微调模型同样在大约 7000 个 step 处在验证集上的性能表现就趋于平稳，而从头训练模型在 50 个 epoch 训练结束时在验证集上的性能表现仍在波动。综上所述，基于信号域迁移的微调模型相比于从头训练的模型，在真实信号数据集上的训练速度得到了较大提升。

4.6 本章小结

本章在上一章的基于信号多视角逆投影融合的三维点云重建方法基础上提出了一种基于信号域迁移的三维点云重建方法，以提升三维重建网络模型的数据效率、训练速度以及性能表现。为了产生规模巨大的仿真信号数据集，本文提出了一个基于信号建模的雷达信号仿真算法，以及一个信号域适应网络模块，通过这两个步骤可以为公开数据集中的大量三维模型生成对应的仿真信号，以此来构建仿真信号数据集。之后采取“预训练-微调”的两阶段训练范式将上一章的三维重建网络模型在仿真域和真实域之间进行域迁移。

本章实验结果表明，本文通过信号仿真算法和信号域适应网络模块产生的仿真信号达到了足够高的精度表现；同时，基于信号域迁移的三维点云重建方法大大提升了三维重建网络模型在真实信号数据集上的训练速度以及数据效率，并且一定程度上提升了模型的性能表现。

5 结论与展望

5.1 结论

到目前为止，三维重建技术已经取得了巨大的成功，并在多个领域得到了广泛应用，然而，在物流分拣领域以及安检领域中，由于物体很大可能被外包装覆盖以及可能处在各种恶劣可见条件下，传统的基于图像的三维重建方法无法适用，而现有的基于射频频的三维重建方法又大多成本高昂。针对上述问题，本文做出了两个贡献。

第一，本文提出了一种基于信号多视角逆投影融合的三维点云重建方法，该方法仅使用一个低成本的单发单收商用超宽带雷达去捕获物体的反射雷达信号，本文利用物体的移动为雷达构建大量虚拟天线提升雷达感知能力，之后通过背景反射消减和有效距离箱定位获取去噪后的有效雷达信号；随后通过三维重建神经网络模型从物体多视角雷达信号中提取物体三维特征得到物体多视角深度图，为了缓解雷达信号数据集的样本单一问题，本文设计了一种雷达信号数据增强算法；最终，通过对网络输出的多视角深度图进行逆投影和点云融合得到最终的重建点云。实验结果表明，本文方法在真实采集的数据集上获得了不错的重建精度，并且在物体被遮挡情况下仍保持良好性能。

其次，本文针对基于深度学习的三维点云重建方法存在的真实雷达信号数据采集耗时、标注费时以及网络模型迁移时训练成本高等问题，设计了一种基于信号域迁移的三维点云重建方法。本文首先提出了基于信号建模的雷达信号仿真算法以及信号域适应网络模块，并以此构建了一个大规模的仿真信号数据集，之后采取“预训练-微调”的两阶段训练对三维重建神经网络模型进行迁移学习。实验结果表明，这种迁移学习的方法相比于在真实信号数据集上从头训练，大大提升了三维重建网络模型的数据效率、训练速度，并在一定程度上提升了性能表现。

5.2 展望

本文的基于信号多视角融合与域迁移的三维点云重建方法在本文所采集的数据集上取得了不错的性能表现，但仍有以下改进空间：

1) 受限于 3D 打印成本，本文采集的数据集中仅包含 8 个类别的 48 个不同三维物体的雷达数据以及标注数据，相较于计算机视觉领域的 ShapeNet 等大型公开数据集，本文的数据集在物体类别数量以及类内物体数量仍存在不足，因此本文方法在大规模数据集上的表现仍需考验，后续工作应该设计更低成本的数据采集方案，扩展数据集中的物体类别数量以及物体数量。

2) 受限于 3D 打印材料选择单一，本文所打印的物体均使用同样的树脂材料，因此本文方法在物体材质多样的场景下的性能表现仍需考验，后续工作应该扩充数据集中物体材质类别，同时，可以考虑利用不同材料反射信号的数据分布差异，让神经网络

模型同时对目标物体的材质进行预测。

3) 本文的三维点云重建方法受限于超宽带雷达本身感知能力的不足, 相较于基于图像的重建方法, 在性能表现上仍有差异, 尤其是一些雷达反射截面较小的物体, 后续工作应该考虑提升这类物体的性能, 例如从神经网络模型出发, 设计出有更强特征提取能力的网络模块, 能够从小雷达反射截面物体的反射信号中提取足够的三维结构信息。

参考文献

- [1] 杨亚鹏. 电子元器件视觉三维重建系统及应用研究[J]. 电子元器件与信息技术, 2024, 8(01): 12-15.
- [2] 陈新度, 徐学, 高萌, 等. 机械臂环境三维重建与避障算法研究[J]. 机械设计与制造, 2024(01): 347-352+358.
- [3] 黎玲, 金恒, 刘杰, 等. 基于工业 CT 图像的自适应三维网格模型重建[J]. 光学学报, 2023, 43(03): 243-252.
- [4] 程斌, 杨勇, 徐崇斌, 等. 基于 NeRF 的文物建筑数字化重建[J]. 航天返回与遥感, 2023, 44(01): 40-49.
- [5] 顾珈静, 刘春, 董涛. 基于多目视觉的小型文物精细感知与三维重建[J]. 工程勘察, 2023, 51(03): 44-50.
- [6] 陈思瀚, 孙保燕, 蒋嘉鑫, 等. 多源数据融合的三维重建技术在文物保护中的应用[J]. 科技创新与生产力, 2023, 44(06): 141-144.
- [7] 成欢, 王硕, 李孟, 等. 面向自动驾驶场景的神经辐射场综述[J]. 图学学报, 2023, 44(06): 1091-1103.
- [8] 李鸿楠. 面向数据标注的实际驾驶场景三维重建算法设计与实现[D]. 哈尔滨工业大学, 2023.
- [9] 纪淮宁. 基于语义先验的视觉多目标跟踪 SLAM 算法研究[D]. 华南理工大学, 2023.
- [10] LOWE D G. Object recognition from local scale-invariant features[C]//Proceedings of the seventh IEEE international conference on computer vision: vol. 2. 1999: 1150-1157.
- [11] BAY H, ESS A, TUYTELAARS T, et al. Speeded-up robust features (SURF)[J]. Computer vision and image understanding, 2008, 110(3): 346-359.
- [12] RUBLEE E, RABAU D V, KONOLIGE K, et al. ORB: An efficient alternative to SIFT or SURF[C]//2011 International conference on computer vision. 2011: 2564-2571.
- [13] VISWANATHAN D G. Features from accelerated segment test (fast)[C]//Proceedings of the 10th workshop on image analysis for multimedia interactive services, London, UK. 2009: 6-8.
- [14] CALONDER M, LEPETIT V, STRECHA C, et al. Brief: Binary robust independent elementary features[C]//Computer Vision—ECCV 2010: 11th European Conference on Computer Vision, Heraklion, Crete, Greece, September 5-11, 2010, Proceedings, Part IV 11. 2010: 778-792.
- [15] WU C. Towards linear-time incremental structure from motion[C]//2013 International Conference on 3D Vision-3DV 2013. 2013: 127-134.
- [16] CUI H, SHEN S, GAO W, et al. Efficient large-scale structure from motion by fusing auxiliary imaging information[J]. IEEE Transactions on Image Processing, 2015, 24(11): 3561-3573.
- [17] CUI H, GAO X, SHEN S, et al. HSfM: Hybrid structure-from-motion[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1212-1221.
- [18] GALLUP D, FRAHM J M, MORDOHAI P, et al. Real-time plane-sweeping stereo with multiple sweeping directions[C]//2007 IEEE Conference on Computer Vision and Pattern Recognition. 2007: 1-8.
- [19] BLEYER M, RHEMANN C, ROTHER C. Patchmatch stereo-stereo matching with slanted support

- windows.[C]//Bmvc: vol. 11. 2011: 1-11.
- [20] SCHWALBE E, MAAS H G, SEIDEL F. 3D building model generation from airborne laser scanner data using 2D GIS data and orthogonal point cloud projections[J]. Proceedings of ISPRS WG III/3, III/4, 2005, 3: 12-14.
 - [21] WEISS T, SCHIELE B, DIETMAYER K. Robust driving path detection in urban and highway scenarios using a laser scanner and online occupancy grids[C]//2007 IEEE Intelligent Vehicles Symposium. 2007: 184-189.
 - [22] 魏征. 车载 LiDAR 点云中建筑物的自动识别与立面几何重建[D]. 武汉大学, 2012.
 - [23] 李诗锐, 李琪, 李海洋, 等. 基于 Kinect v2 的实时精确三维重建系统[J]. 软件学报, 2016, 27(10): 2519-2529.
 - [24] QIAN K, HE Z, ZHANG X. 3D point cloud generation with millimeter-wave radar[J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2020, 4(4): 1-23.
 - [25] YANIK M E, WANG D, TORLAK M. 3-D MIMO-SAR imaging using multi-chip cascaded millimeter-wave sensors[C]//2019 IEEE global conference on signal and information processing (GlobalSIP). 2019: 1-5.
 - [26] FAN H, SU H, GUIBAS L J. A point set generation network for 3d object reconstruction from a single image[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 605-613.
 - [27] YU X, RAO Y, WANG Z, et al. PointR: Diverse point cloud completion with geometry-aware transformers[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 12498-12507.
 - [28] WANG N, ZHANG Y, LI Z, et al. Pixel2mesh: Generating 3d mesh models from single rgb images [C]//Proceedings of the European conference on computer vision (ECCV). 2018: 52-67.
 - [29] ZHANG Y, LIU Z, LIU T, et al. RealPoint3D: An efficient generation network for 3D object reconstruction from a single image[J]. IEEE Access, 2019, 7: 57539-57549.
 - [30] CHANG A X, FUNKHOUSER T, GUIBAS L, et al. Shapenet: An information-rich 3d model repository[J]. arXiv preprint arXiv:1512.03012, 2015.
 - [31] PAN J, LI J, HAN X, et al. Residual meshnet: Learning to deform meshes for single-view 3d reconstruction[C]//2018 International Conference on 3D Vision (3DV). 2018: 719-727.
 - [32] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
 - [33] WEN C, ZHANG Y, LI Z, et al. Pixel2mesh++: Multi-view 3d mesh generation via deformation[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 1042-1051.
 - [34] BAUTISTA M A, TALBOTT W, ZHAI S, et al. On the generalization of learning-based 3d reconstruction[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2021: 2180-2189.
 - [35] THAI A, STOJANOV S, UPADHYA V, et al. 3d reconstruction of novel object shapes from single images[C]//2021 International Conference on 3D Vision (3DV). 2021: 85-95.
 - [36] COLLINS J, GOEL S, DENG K, et al. Abo: Dataset and benchmarks for real-world 3d object understanding[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 21126-21136.

-
- [37] YAO Y, LUO Z, LI S, et al. Mvsnet: Depth inference for unstructured multi-view stereo[C]// Proceedings of the European conference on computer vision (ECCV). 2018: 767-783.
- [38] YANG J, MAO W, ALVAREZ J M, et al. Cost volume pyramid based depth inference for multi-view stereo[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 4877-4886.
- [39] YU Z, GAO S. Fast-mvsnet: Sparse-to-dense multi-view stereo with learned propagation and gaussian newton refinement[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 1949-1958.
- [40] YI H, WEI Z, DING M, et al. Pyramid multi-view stereo net with self-adaptive view aggregation[C]//Computer Vision—ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part IX 16. 2020: 766-782.
- [41] WEI Z, ZHU Q, MIN C, et al. Aa-rmvsnet: Adaptive aggregation recurrent multi-view stereo network [C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 6187-6196.
- [42] MA X, GONG Y, WANG Q, et al. Epp-mvsnet: Epipolar-assembling based depth prediction for multi-view stereo[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 5732-5740.
- [43] MILDENHALL B, SRINIVASAN P P, TANCİK M, et al. Nerf: Representing scenes as neural radiance fields for view synthesis[J]. Communications of the ACM, 2021, 65(1): 99-106.
- [44] MÜLLER T, EVANS A, SCHIED C, et al. Instant neural graphics primitives with a multiresolution hash encoding[J]. ACM transactions on graphics (TOG), 2022, 41(4): 1-15.
- [45] FRIDOVICH-KEIL S, YU A, TANCİK M, et al. Plenoxels: Radiance fields without neural networks [C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 5501-5510.
- [46] CHEN A, XU Z, GEIGER A, et al. Tensorf: Tensorial radiance fields[C]//European conference on computer vision. 2022: 333-350.
- [47] YU A, YE V, TANCİK M, et al. pixelnerf: Neural radiance fields from one or few images[C]// Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 4578-4587.
- [48] NIEMEYER M, BARRON J T, MILDENHALL B, et al. Regnerf: Regularizing neural radiance fields for view synthesis from sparse inputs[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 5480-5490.
- [49] KERBL B, KOPANAS G, LEIMKÜHLER T, et al. 3d gaussian splatting for real-time radiance field rendering.[J]. ACM Trans. Graph., 2023, 42(4): 139-1.
- [50] ZHAO M, LIU Y, RAGHU A, et al. Through-Wall Human Mesh Recovery Using Radio Signals[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2019.
- [51] XUE H, JU Y, MIAO C, et al. mmMesh: Towards 3D real-time dynamic human mesh construction using millimeter-wave[C]//Proceedings of the 19th Annual International Conference on Mobile Systems, Applications, and Services. 2021: 269-282.
- [52] XUE H, CAO Q, MIAO C, et al. Towards generalized mmwave-based human pose estimation through signal augmentation[C]//Proceedings of the 29th Annual International Conference on Mobile Computing and Networking. 2023: 1-15.

- [53] SUN Y, HUANG Z, ZHANG H, et al. 3DRIMR: 3D Reconstruction and Imaging via mmWave Radar based on Deep Learning[C]//2021 IEEE International Performance, Computing, and Communications Conference (IPCCC). 2021: 1-8.
- [54] SUN Y, ZHANG H, HUANG Z, et al. Deeppoint: A deep learning model for 3d reconstruction in point clouds via mmwave radar[J]. arXiv preprint arXiv:2109.09188, 2021.
- [55] SUN Y, ZHANG H, HUANG Z, et al. R2p: A deep learning model from mmwave radar to point cloud[C]//International Conference on Artificial Neural Networks. 2022: 329-341.
- [56] ZHENG T, CHEN Z, ZHANG S, et al. MoRe-Fi: Motion-robust and fine-grained respiration monitoring via deep-learning UWB radar[C]//Proceedings of the 19th ACM conference on embedded networked sensor systems. 2021: 111-124.
- [57] CHEN Z, ZHENG T, CAI C, et al. MoVi-Fi: Motion-robust vital signs waveform recovery via deep interpreted RF sensing[C]//Proceedings of the 27th annual international conference on mobile computing and networking. 2021: 392-405.
- [58] SKARIA S, AL-HOURANI A, EVANS R J. Deep-Learning Methods for Hand-Gesture Recognition Using Ultra-Wideband Radar[J]. IEEE Access, 2020, 8: 203580-203590.
- [59] NOORI F M, UDDIN M Z, TORRESEN J. Ultra-wideband radar-based activity recognition using deep learning[J]. IEEE Access, 2021, 9: 138132-138143.
- [60] WANG Z, CHEN Z, SINGH A D, et al. UWHear: Through-wall extraction and separation of audio vibrations using wireless signals[C]//Proceedings of the 18th Conference on Embedded Networked Sensor Systems. 2020: 1-14.
- [61] ZHUANG F, QI Z, DUAN K, et al. A comprehensive survey on transfer learning[J]. Proceedings of the IEEE, 2020, 109(1): 43-76.
- [62] HENDRYCKS D, LEE K, MAZEIKA M. Using pre-training can improve model robustness and uncertainty[C]//International conference on machine learning. 2019: 2712-2721.
- [63] KATHAMUTHU N D, SUBRAMANIAM S, LE Q H, et al. A deep transfer learning-based convolution neural network model for COVID-19 detection using computed tomography scan images for medical applications[J]. Advances in Engineering Software, 2023, 175: 103317.
- [64] ZHANG W, WANG Z, LI X. Blockchain-based decentralized federated transfer learning methodology for collaborative machinery fault diagnosis[J]. Reliability Engineering & System Safety, 2023, 229: 108885.
- [65] GOMROKI M, HASANLOU M, REINARTZ P. STCD-EffV2T Unet: Semi transfer learning EfficientNetV2 T-Unet network for urban/land cover change detection using Sentinel-2 satellite images [J]. Remote Sensing, 2023, 15(5): 1232.
- [66] HU E J, SHEN Y, WALLIS P, et al. Lora: Low-rank adaptation of large language models.[J]. ICLR, 2022, 1(2): 3.
- [67] YU L, HU Y, XIE X, et al. Complex-Valued Full Convolutional Neural Network for SAR Target Classification[J]. IEEE Geoscience and Remote Sensing Letters, 2020, 17(10): 1752-1756.
- [68] WANG X, CHEN P, XIE H, et al. Through-wall human activity classification using complex-valued convolutional neural network[C]//2021 IEEE radar conference (radarConf21). 2021: 1-4.
- [69] ZHANG Y, HUA Q, JIANG Y, et al. Cv-MotionNet: Complex-valued convolutional neural network for SAR moving ship targets classification[C]//2021 IEEE International Geoscience and Remote

- Sensing Symposium IGARSS. 2021: 4280-4283.
- [70] MU H, ZHANG Y, JIANG Y, et al. CV-GMTINet: GMTI using a deep complex-valued convolutional neural network for multichannel SAR-GMTI system[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 60: 1-15.
- [71] KARRAS T, AILA T, LAINE S, et al. Progressive growing of gans for improved quality, stability, and variation[J]. arXiv preprint arXiv:1710.10196, 2017.
- [72] LIN C H, KONG C, LUCEY S. Learning efficient point cloud generation for dense 3d object reconstruction[C]//proceedings of the AAAI Conference on Artificial Intelligence: vol. 32: 1. 2018.
- [73] KORANY B, KARANAM C R, CAI H, et al. XModal-ID: Using WiFi for through-wall person identification from candidate video footage[C]//The 25th Annual International Conference on Mobile Computing and Networking. 2019: 1-15.